

Guide d'etude DOTA hors ligne

Parcours de 8 heures - detection, YOLO-OBB, causalite, resultats, exercices et questions orales

Conseil : repondre de memoire avant de lire. Les exercices et leur corrige sont separees.

Pack d'étude hors ligne - projet DOTA

Ce dossier est conçu pour un vol de 8 heures sans Internet. Il ne faut pas tout lire passivement. Le but est de pouvoir expliquer le projet, refaire les raisonnements essentiels et reconnaître les limites méthodologiques.

Avant de couper Internet

1. Faire un `git pull` sur l'ordinateur emporté pendant le vol.
2. Ouvrir `output/notebook/projet_dota.html` dans un navigateur.
3. Ouvrir `output/pdf/guide_etude_vol_dota.pdf`.
4. Couper temporairement le Wi-Fi et vérifier que les figures restent visibles.
5. Garder tout le dossier du dépôt sur le disque local.

Le notebook est pré-exécuté : son code, ses tableaux, ses graphiques et ses résultats sont déjà sauvegardés. Pour la lecture, aucun noyau Jupyter, dataset, poids YOLO ou environnement Python n'est nécessaire. Ne pas utiliser `Restart` and `Run All` sur cet ordinateur, car les données et poids volumineux sont volontairement ignorés par Git.

Méthode de travail pour chaque bloc

Utiliser toujours le même cycle :

1. Fermer le document et répondre de mémoire aux questions de départ.
2. Lire seulement ce qui manque.
3. Expliquer le concept à voix basse en 20 secondes.
4. Faire un mini-exercice sans regarder la correction.
5. Noter 0, 1 ou 2 :
 - 0 : je bloque ;
 - 1 : je comprends avec de l'aide ;
 - 2 : je peux l'expliquer avec un exemple et une limite.

Une notion n'est pas maîtrisée parce qu'elle semble familière. Elle est maîtrisée quand la réponse sort sans support.

Programme principal de 8 heures

Chaque bloc dure 50 minutes, suivi de 10 minutes de pause. Les pauses font partie du programme : elles évitent de confondre fatigue et incompréhension.

Heure 1 - Carte du projet et du bareme

- Lire `01_projet_de_bout_en_bout.md`.
- Dessiner de mémoire le pipeline : images brutes -> tuiles -> labels ->

entraînement -> prédictions -> métriques -> table causale -> effets.

- Associer chaque étape aux six questions du sujet.
- Expliquer pourquoi le split est fait par image source et non par tuile.

Livrable personnel : une page manuscrite contenant le pipeline et les six questions.

Heure 2 - Détection, IoU et métriques

- Étudier les cartes 1 à 6 de `concepts_oraux_ml_causalite.md`.
- Lire les sections IoU, matching, precision, recall, AP et mAP dans

`02_detection_yolo_obb.md`.

- Faire les exercices D1 à D6 de

05_exercices_sans_corrige.md.

Livrable personnel : expliquer la différence entre une prédiction confiante et une prédiction correcte.

Heure 3 - YOLO, OBB et entraînement

- Étudier les cartes 7 et 8 de concepts_oraux_ml_causalite.md.
- Revoir backbone, neck, head, loss, transfert learning et NMS.
- Comparer HBB et OBB sans dire qu'OBB est automatiquement meilleur.
- Lire dans le notebook les cellules de la question 3.

Livrable personnel : réponse de 90 secondes à "Pourquoi YOLO-OBB pour DOTA ?".

Heure 4 - Tuilage, données et reproductibilité

- Relire la partie pipeline de

01_projet_de_bout_en_bout.md.

- Examiner preparation_summary.json et les manifestes CSV.
- Répondre aux questions sur les fragments de bord, les tuiles négatives, les classes rares et la stratification.
- Faire les exercices P1 à P6.

Livrable personnel : défendre les choix 1024 pixels, stride 824 en train et stride 1024 en validation.

Heure 5 - DAG et vocabulaire causal

- Lire 03_causalite_appliquee.md jusqu'à la section sur les hypothèses d'identification.
- Refaire les DAG smoking → cancer et DOTA sans regarder.
- Classer chaque variable comme traitement, outcome, confounder, mediator, collider ou variable de précision.
- Faire les exercices C1 à C7.

Livrable personnel : expliquer pourquoi corrélation n'est pas causalité avec un exemple DOTA.

Heure 6 - Estimation causale

- Étudier régression ajustée, score de propension, IPW, g-computation et AIPW.
- Comprendre le rôle du cross-fitting et du bootstrap groupe par image.
- Étudier l'arbre causal et la forêt sur pseudo-outcomes.
- Faire les exercices C8 à C14.

Livrable personnel : comparer AIPW et différence brute en moins d'une minute.

Heure 7 - Résultats réels et limites

- Lire 04_resultats_et_interpretation.md.
- Ouvrir les figures dans outputs/analysis/.
- Trouver trois constats prédictifs, deux constats causaux et cinq limites.
- Vérifier que chaque conclusion est soutenue par une mesure.

Livrable personnel : une conclusion de deux minutes sans confondre mAP et effet causal.

Heure 8 - Simulation orale et examen

- Utiliser 06_questions_orales.md.

- Tirer 20 questions au hasard.
- Répondre d'abord sans support, puis corriger.
- Faire le mini-examen final de

05_exercices_sans_corrige.md.

- Consulter 07_corrige.md seulement à la fin.

Livrable personnel : liste des cinq notions qui restent fragiles.

Parcours réduit de 3 heures

Si la fatigue est forte :

1. Heure 1 : carte du projet, tuilage, HBB vs OBB.
2. Heure 2 : IoU, précision, recall, mAP, DAG, confounder, collider.
3. Heure 3 : résultats réels, limites et 15 questions orales.

Ne pas sacrifier les limites. Une réponse prudente et rigoureuse vaut mieux qu'une affirmation forte non défendable.

Index des ressources

- 01_projet_de_bout_en_bout.md : fil complet

du projet et correspondance avec le barème.

- 02_detection_yolo_obb.md : détection, YOLO,

métriques, entraînement et erreurs.

- 03_causalite_appliquee.md : DAG, identification,

estimateurs et hétérogénéité.

- 04_resultats_et_interpretation.md :

chiffres et figures produits par l'expérience.

- 05_exercices_sans_corrige.md : exercices.
- 06_questions_orales.md : questions courtes.
- 07_corrige.md : solutions séparées.
- flashcards.csv : cartes importables dans Anki ou lisibles dans un tableur.
- concepts_oraux_ml_causalite.md : cartes orales détaillées déjà commencées.

Grille finale d'auto-évaluation

Bloc	Score avant	Score après	Preuve de maîtrise
Pipeline complet			Je le dessine sans support
Tuilage et fuite			Je justifie le split par image
IoU, AP, mAP			Je donne formules et limites
YOLO et OBB			Je relie architecture et DOTA
DAG			Je distingue les types de nœuds
AIPW			Je compare aux méthodes simples
Arbre causal			J'explique hétérogénéité et prudence
Résultats réels			Je cite des chiffres exacts
Limites			J'en explique au moins cinq

Le projet DOTA de bout en bout

Le probleme en une phrase

Le projet doit localiser et classier des objets dans de grandes images aeriennes, puis etudier causalement si le fait qu'un objet soit tres petit reduit sa probabilite d'etre correctement detecte.

Il contient donc deux problemes differents :

- probleme predictif : ou sont les objets et quelle est leur classe ?
- probleme causal : quel serait l'effet du traitement "objet tres petit" sur

la detection, apres ajustement sur des differences observables pertinentes ?

Une bonne performance predictive ne prouve pas un effet causal.

Le pipeline a savoir dessiner

```
[text]
DOTA-v1.0 brut
|
+-- images train et validation separees
+-- annotations OBB a 8 coordonnees
+-- source, GSD, difficult
|
v
Audit et variables derivees
|
+-- aire, ratio de forme, orientation
+-- densite, classe dominante, type de scene
+-- controles de validite
|
v
Selection stratifiee par image source
|
+-- 180 images train
+-- 60 images validation
+-- 15 classes couvertes
|
v
Tuilage 1024 x 1024
|
+-- train : stride 824, augmentation de couverture
+-- validation : stride 1024, evaluation moins redondante
+-- fragments ambigus rejetes
+-- tuiles negatives echantillonnees
|
+-----+
|               |
v               v
labels HBB      labels OBB
|               |
v               v
YOL026n HBB     YOL026n OBB
baseline        modele principal
|               |
+-----+-----+
|
v
Evaluation validation
|
+-- precision, recall, mAP50, mAP50-95
+-- AP par classe
+-- predictions visuelles
+-- performance par taille et orientation
|
v
Matching OBB prediction-verite terrain
|
v
Table causale unique par objet
|
+-- D : tres petit
+-- Y : classe correcte et IoU >= 0.50
+-- X : classe, orientation, densite, source, GSD,
      ratio de forme, position du centre dans la tuile
|
v
Difference brute, g-computation, IPW, AIPW
|
v
Arbre causal honnete + foret sur pseudo-outcomes
|
v
Interpretation, incertitude, sensibilite et limites
```

Pourquoi utiliser un sous-ensemble ?

DOTA est volumineux et les images sont grandes. Un sous-ensemble permet :

- une experience executable sur une RTX 4060 de 8 Go ;
- plusieurs modeles et controles dans un temps realiste ;
- une analyse causale par objet sans plusieurs jours de calcul ;

- une reproduction pédagogique.

Ce choix est acceptable seulement si la sélection est défendable. Ici elle est faite au niveau de l'image, avec couverture des 15 classes et une strate classe dominante x densité. Les classes rares restent rares : le projet ne prétend pas que la stratification annule le déséquilibre.

Pourquoi sélectionner avant de tuiler ?

Si on tuile d'abord puis qu'on répartit les tuiles au hasard, deux tuiles de la même image peuvent se retrouver dans train et validation. Elles partagent le même paysage, la même texture, la même source et parfois les mêmes objets.

Le modèle pourrait reconnaître le contexte plutôt que généraliser. La métrique de validation serait alors trop optimiste.

La bonne unité de séparation est l'image source. Toutes ses tuiles restent dans le même split.

Choix de tuilage

Taille 1024

Une tuile de 1024 pixels :

- est beaucoup plus petite qu'une image DOTA complète ;
- conserve assez de contexte autour des objets ;
- reste compatible avec la mémoire GPU ;
- permet ensuite un redimensionnement vers 640 ou 1024 pour YOLO.

Une tuile trop petite coupe plus d'objets et perd le contexte. Une tuile trop grande réduit les objets minuscules lors du redimensionnement et augmente le coût mémoire.

Stride 824 en train

Le chevauchement de 200 pixels augmente la probabilité qu'un objet proche d'un bord apparaisse entier dans au moins une tuile. Cela enrichit le train, mais peut dupliquer un objet. Le manifeste conserve `object_id` et `tile_instances_for_object` pour rendre cette duplication visible.

Stride 1024 en validation

La validation doit être la moins redondante possible. Un stride sans chevauchement est donc préféré. Une dernière position est ajoutée pour couvrir le bord final de l'image, ce qui peut créer un petit chevauchement. Pour l'analyse causale, une seule instance est choisie par objet original.

Gestion des objets aux bords

Pour chaque objet, on calcule la fraction de son aire conservée dans la tuile :

- fraction ≥ 0.70 : objet garde ;
- fraction entre 0.20 et 0.70 : tuile rejetée car le fragment est ambigu ;
- fraction < 0.20 : fragment ignore.

Si un objet partiellement coupé est gardé, son intersection avec la tuile est approximée par une nouvelle boîte orientée minimale. Les coordonnées sont ensuite clipées et normalisées entre 0 et 1.

Ce choix réduit les labels trompeurs. Sa limite est qu'il élimine des tuiles et modifie la distribution des objets proches des bords.

Pourquoi garder des tuiles négatives ?

Une tuile négative ne contient aucun objet annoté. Sans tuiles négatives, le modèle apprendrait surtout que toute image contient forcément un objet. Un échantillon de négatives lui apprend le fond et aide à réduire les faux positifs.

On ne garde pas toutes les tuiles vides parce qu'elles domineraient le dataset et augmenteraient fortement le temps d'entraînement.

Deux représentations, memes images

HBB

La boîte horizontale est dérivée du minimum et maximum des quatre coins :

```
[text]
xmin = min(x1, x2, x3, x4)
xmax = max(x1, x2, x3, x4)
ymin = min(y1, y2, y3, y4)
ymax = max(y1, y2, y3, y4)
```

Le label YOLO contient classe, centre x, centre y, largeur et hauteur. Cette représentation est simple, mais englobe souvent du fond pour un objet diagonal.

OBB

Le label contient la classe et les quatre coins normalisés. Il respecte mieux la géométrie DOTA et permet une IoU orientée.

Pourquoi la comparaison est équitable

- memes images sources ;
- memes tuiles ;
- memes splits ;
- meme graine ;
- meme famille YOLO26n ;
- meme pré-entraînement COCO du backbone ;
- aucune initialisation OBB déjà entraînée sur DOTA.

La tête OBB est différente par nécessité. La comparaison mesure donc surtout l'effet pratique de la représentation et de la tête orientée dans ce protocole.

Ce que fait chaque fichier de code

src/dota_pipeline.py

- lit les annotations DOTA ;
- calcule les variables dérivées ;
- sélectionne les images ;
- découpe et annote les tuiles ;
- produit simultanément HBB et OBB ;
- valide les labels et la séparation.

scripts/prepare_experiment.py

Point d'entrée pour construire le dataset expérimental.

scripts/train_models.py

Entraîne HBB ou OBB, protège les anciens runs, permet une reprise depuis last.pt et enregistre les métadonnées de reproductibilité.

src/experiment_analysis.py

- calcule l'IoU polygonale ;
- associe prédictions et objets par classe ;
- choisit une instance unique par objet ;
- estime les effets par plusieurs méthodes ;

- construit l'arbre et la forêt d'effets.

[scripts/evaluate_experiment.py](#)

Orchestre les évaluations, construit la table causale, génère les CSV, JSON et figures finales.

[scripts/verify_offline_ready.py](#)

Contrôle que l'environnement de vol contient tout le nécessaire.

Correspondance avec les six questions

Question	Reponse du projet
Q1 Exploration	classes, difficulté, dimensions, aires, orientations, visualisations et choix d'algorithmes
Q2 Prétraitement	sélection stratifiée, tuilage, nettoyage, HBB/OBB, variables dérivées et manifeste
Q3 Prédiction	baseline HBB, modèle OBB, métriques globales/par classe et exemples
Q4 Causalité	D, Y, X, DAG, hypothèses et estimand
Q5 Estimation	brut, g-computation, IPW, AIPW, arbre/forêt, IC et sensibilité
Q6 Conclusion	interprétation séparée, limites, figures et reproductibilité

Questions de rappel

Repondre sans regarder le texte :

1. Pourquoi le split doit-il précéder le tuilage ?
2. Pourquoi un stride plus petit est-il utilisé en train ?
3. Pourquoi ne pas garder tous les fragments de bord ?
4. Pourquoi conserver des tuiles négatives ?
5. Pourquoi HBB est-il une baseline utile mais imparfaite ?
6. Pourquoi ne pas initialiser OBB avec des poids déjà ajustés sur DOTA ?
7. Pourquoi une instance unique est-elle choisie pour l'analyse causale ?
8. Quelle colonne relie une instance tuilée à l'objet original ?
9. Quelle partie du pipeline produit l'outcome causal ?
10. Pourquoi un bon mAP ne suffit-il pas pour Q5 ?

Detection, YOLO et boîtes orientées

1. Detection n'est pas classification

Un classifieur global produit une classe pour l'image entière. Un détecteur produit plusieurs objets :

```
[text]
(classe, score de confiance, geometrie de boîte)
```

Dans DOTA, une image peut contenir des centaines d'objets de plusieurs classes. Un classifieur global perdrait leur position et leur nombre. Il est donc inadapté à l'état brut.

Reponse orale en 20 secondes :

La classification dit principalement ce que contient une image. La detection doit aussi dire où se trouve chaque objet, et DOTA peut en contenir beaucoup. Il faut donc prédire plusieurs classes et plusieurs boîtes par image.

2. Representation d'une boîte

HBB

Une HBB reste alignée avec les axes. Elle est souvent représentée par :

```
[text]
(x_centre, y_centre, largeur, hauteur)
```

OBB

Une OBB peut tourner. Dans les labels Ultralytics utilisés ici :

```
[text]
classe x1 y1 x2 y2 x3 y3 x4 y4
```

Les coordonnées sont normalisées par la taille de la tuile.

Perte lors de la conversion

La HBB d'un objet diagonal couvre l'objet plus une zone de fond. Deux objets orientés et proches peuvent aussi produire des HBB qui se chevauchent beaucoup, même si leurs OBB sont bien séparés.

Cette perte peut diminuer la précision de localisation et rendre la NMS plus agressive dans les scènes denses.

3. IoU

Formule :

```
[text]
IoU = aire(intersection) / aire(union)
```

Propriétés :

- IoU = 1 : superposition parfaite ;
- IoU = 0 : aucune intersection ;
- bonne classe avec IoU faible : localisation incorrecte ;
- IoU ne mesure pas directement la confiance ou la calibration.

Pour OBB, l'intersection doit respecter la rotation. Calculer seulement l'IoU des HBB autour de deux OBB peut surestimer leur chevauchement.

Mini-calcul

Deux rectangles de surface 100 se chevauchent sur une surface 40 :

```
[text]
union = 100 + 100 - 40 = 160
IoU = 40 / 160 = 0.25
```

Le piège classique est de diviser par la somme 200 sans retirer l'intersection comptée deux fois.

4. Matching prediction-verite terrain

Il ne suffit pas de calculer chaque IoU independamment. Une prediction ne doit pas valider plusieurs objets.

Le pipeline :

1. separe les objets par classe ;
2. calcule une matrice d'IoU ;
3. applique une association un-a-un qui maximise l'IoU totale ;
4. marque un objet correct si la classe est la meme, la confiance suffisante

et l'IoU au-dessus du seuil.

Cette association evite de compter deux fois une unique detection.

5. TP, FP et FN

- TP : prediction associee a un objet de meme classe avec IoU suffisante.
- FP : prediction non associee correctement.
- FN : objet reel sans prediction correcte.

Une mauvaise classe produit generalement un FP pour la classe predite et un FN pour la vraie classe.

Une boite de bonne classe mais mal placee produit aussi un FP et un FN selon la regle d'evaluation.

6. Precision, recall et F1

```
[text]
precision = TP / (TP + FP)
recall    = TP / (TP + FN)
F1        = 2 * precision * recall / (precision + recall)
```

Interpretation :

- precision : fiabilite des detections annoncees ;
- recall : couverture des objets reels ;
- F1 : compromis pour un seuil de confiance donne.

Le seuil de confiance change le compromis. Un seuil eleve elimine des detections incertaines : souvent precision augmente et recall diminue.

7. AP et mAP

Pour une classe :

1. trier les predictions par confiance ;
2. faire varier le seuil ;
3. calculer les couples precision-recall ;
4. mesurer l'aire sous la courbe precision-recall : AP.

La mAP est la moyenne des AP sur les classes.

mAP50

Une prediction est localement correcte a partir d'une IoU de 0.50. Cette metrique est relativement tolerante.

mAP50-95

On moyenne l'AP pour des seuils IoU de 0.50 a 0.95 par pas de 0.05. Elle penalise plus fortement les boites imprecises.

Si mAP50 est nettement plus haute que mAP50-95, le modele reconnait parfois l'objet mais la localisation precise reste difficile.

Limite de la moyenne

Chaque classe contribue a la mAP, mais une seule valeur masque :

- les classes rares ;
- les objets minuscules ;
- les orientations extremes ;
- les scenes tres denses ;
- les sources d'image difficiles.

Il faut donc aussi etudier AP par classe et performance par sous-groupe.

8. Score de confiance

Le score sert a classer et filtrer les detections. Il n'est pas une garantie de verite et n'est pas automatiquement une probabilite bien calibree.

Trois dimensions restent distinctes :

- classe correcte ;
- geometrie correcte ;
- confiance elevee.

Une prediction peut etre tres confiante et fausse.

9. NMS

La Non-Maximum Suppression retire les boites redondantes :

1. garder la boite la plus confiante ;
2. comparer son IoU aux autres ;
3. supprimer les boites trop chevauchantes ;
4. continuer.

Dans une scene dense, une NMS trop agressive peut supprimer un vrai voisin. Avec OBB, une NMS orientee distingue mieux certains objets diagonaux proches.

10. YOLO en une vue

YOLO traite l'image dans un passage principal du reseau et produit de nombreux candidats de detection.

Backbone

Extrait des motifs visuels de complexite croissante :

- bords et textures dans les premieres couches ;
- formes et parties d'objets plus loin.

Neck

Combine plusieurs echelles de features. C'est crucial pour DOTA :

- grandes structures comme les terrains ;
- petits vehicules de quelques pixels.

Head

Produit les classes, scores et parametres de boites. La tete OBB doit aussi représenter l'orientation.

Reponse orale :

Le backbone extrait les caractéristiques, le neck combine plusieurs échelles et la head transforme ces caractéristiques en classes, confiances et boîtes. Pour DOTA, le multi-échelle et la tête orientée sont particulièrement utiles.

11. Loss et optimisation

La loss d'entraînement combine plusieurs erreurs, notamment :

- erreur de localisation ;
- erreur de classification ;
- erreur liée aux scores ;
- composante d'angle pour OBB.

La rétropropagation calcule comment chaque poids contribue à cette erreur. L'optimiseur met ensuite les poids à jour.

Attention :

- loss train basse ne garantit pas la généralisation ;
- mAP validation est une métrique d'évaluation, pas la loss ;
- une hausse de la performance train avec stagnation validation suggère un

overfitting.

12. Epoch, batch et learning rate

Epoch

Un passage approximatif sur tout le train. Davantage d'époques donne plus d'occasions d'apprendre, mais peut mener à l'overfitting.

Batch

Nombre d'images traitées avant une mise à jour des poids. Un grand batch utilise plus de mémoire et donne un gradient souvent moins bruyant.

Learning rate

Amplitude des mises à jour :

- trop grand : apprentissage instable ;
- trop petit : apprentissage lent ou bloqué ;
- scheduler : le fait varier pendant l'entraînement.

13. Transfert learning

Le backbone part de poids appris sur COCO. Il connaît déjà des motifs visuels généraux, puis il est ajusté sur DOTA.

Dans cette expérience, HBB et OBB utilisent le même point de départ COCO autant que leur architecture le permet. Aucun poids OBB déjà ajusté sur DOTA n'est utilisé. Sinon OBB aurait un avantage expérimental difficile à interpréter.

14. Augmentations

Les augmentations changent les exemples train sans toucher à la validation :

- couleur et luminosité ;
- translation et échelle ;
- mosaïcs ;
- retournement horizontal.

Elles peuvent améliorer la généralisation. Elles doivent transformer correctement les boîtes. Une augmentation visuelle dont les labels ne suivent pas rend l'entraînement faux.

Une augmentation d'une image train reste train. Elle ne doit jamais migrer en validation.

15. Petits objets

Les petits objets sont difficiles parce que :

- ils contiennent peu de pixels ;
- le redimensionnement les réduit encore ;
- leurs bords sont sensibles à une erreur de quelques pixels ;
- ils apparaissent souvent dans des zones denses ;
- une petite erreur absolue produit une forte baisse d'IoU.

Améliorations possibles :

- augmenter `imgsz` ;
- utiliser des tuiles adaptées ;
- garder un neck multi-échelle ;
- entraîner plus longtemps ;
- sur-échantillonner avec prudence les scènes utiles ;
- analyser le seuil de confiance et `max_det`.

16. Desequilibre de classes

Un grand nombre de `small-vehicle` ne compense pas le manque de `helicopter`. Une métrique globale peut être dominée par les classes faciles ou fréquentes.

Contrôles :

- couverture de toutes les classes ;
- AP par classe ;
- exemples d'erreurs pour classes rares ;
- limites explicites ;
- éventuellement pondération ou sur-échantillonnage, sans fabriquer de

validation artificielle.

17. Overfitting et underfitting

Underfitting

- loss encore élevée ;
- train et validation faibles ;
- modèle, résolution ou durée insuffisants.

Overfitting

- train continue de s'améliorer ;
- validation stagne ou baisse ;
- écart train-validation grand.

Early stopping

Arrête après une période sans amélioration. Il économise du calcul, mais ne remplace pas l'analyse des courbes.

18. Pourquoi HBB peut parfois sembler meilleure

OBB est mieux adaptée géométriquement, mais elle doit apprendre un problème plus complexe. Avec peu d'époques ou peu de données :

- la tête OBB a plus à apprendre ;
- l'angle ajoute une source d'erreur ;
- l'optimisation peut demander plus de temps ;
- la métrique orientée est plus stricte.

Une baseline HBB supérieure dans un protocole court ne prouve donc pas que les orientations sont inutiles. Il faut interpréter données, durée, résolution et métrique ensemble.

19. Checklist d'analyse d'une courbe

Pour chaque run :

1. Combien d'époques ont réellement fini ?
2. Quelle époque a produit best . pt ?
3. Les losses train baissent-elles ?
4. mAP validation augmente-t-elle encore ?
5. Precision et recall sont-elles déséquilibrées ?
6. Les classes rares ont-elles une AP presque nulle ?
7. Le meilleur modèle est-il la dernière époque ?
8. L'early stopping s'est-il activé ?
9. La résolution et max_det sont-ils adaptés aux scènes denses ?
10. Les exemples visuels confirment-ils les chiffres ?

20. Questions de rappel rapide

1. Pourquoi une bonne classe ne suffit-elle pas pour un TP ?
2. Pourquoi l'union retire-t-elle l'intersection une fois ?
3. Comment une prédiction peut-elle créer à la fois FP et FN ?
4. Que change le seuil de confiance ?
5. Quelle différence entre AP et mAP ?
6. Pourquoi mAP50-95 est-elle plus stricte ?
7. Quel est le risque d'une NMS forte dans un parking ?
8. Quel rôle joue le neck ?
9. Pourquoi le transfert learning aide-t-il ?
10. Pourquoi imgsz=1024 peut aider les petits objets ?
11. Pourquoi peut-il aussi ralentir l'entraînement ?
12. Pourquoi OBB n'est-elle pas garantie de battre HBB ?
13. Quelle métrique montre surtout les objets manqués ?
14. Pourquoi faut-il AP par classe ?
15. Comment reconnaître un overfitting ?

Causalite appliquee aux erreurs du detecteur

1. Prediction, association et causalite

Prediction

Question :

Peut-on predire si cet objet sera correctement detecte ?

Une forte performance predictive signifie que les variables disponibles contiennent de l'information sur l'outcome. Elle ne dit pas ce qui arriverait si on changeait une variable.

Association

Question :

Le taux de detection est-il different entre petits et grands objets ?

Une difference observee peut venir de la taille, mais aussi des classes, de la resolution, de la densite, de la source ou d'autres facteurs.

Causalite

Question :

Pour des objets comparables, que deviendrait la probabilite de detection si l'objet etait dans la condition "tres petit" plutot que "non tres petit" ?

Cette question compare deux mondes potentiels. Un seul est observe pour chaque objet. L'autre est contrefactuel.

2. Cadre des outcomes potentiels

Pour l'objet i :

[text]
 $Y_i(1)$ = outcome si l'objet est tres petit
 $Y_i(0)$ = outcome si l'objet n'est pas tres petit

Effet individuel :

[text]
 $\tau_i = Y_i(1) - Y_i(0)$

Effet moyen :

[text]
 $ATE = E[Y(1) - Y(0)]$

On n'observe jamais les deux outcomes pour le meme objet. C'est le probleme fondamental de l'inference causale. Les methodes utilisent d'autres objets comparables et des hypotheses d'identification.

3. Question retenue dans DOTA

Traitement D :

- $D = 1$ si l'aire relative de l'objet dans sa tuile est inferieure ou egale

au premier quartile calcule sur les objets train uniques ;

- $D = 0$ sinon.

Outcome Y :

- $Y = 1$ si le modele OBB associe une prediction de meme classe, de confiance

au moins 0.25 et d'IoU orientee au moins 0.50 ;

- $Y = 0$ sinon.

Estimand :

- effet moyen du traitement dans la population des objets uniques du sous-ensemble de validation.

Question :

Quel est l'effet d'être un objet très petit sur la probabilité d'une détection correcte, après ajustement sur la classe, l'orientation, la densité, la source, le GSD, le ratio de forme et les conditions de tuilage ?

4. Prudence sur le mot traitement

"Rendre un objet petit" n'est pas une intervention physique unique :

- éloigner le capteur ;
- diminuer la résolution ;
- changer la taille réelle de l'objet ;
- redimensionner l'image.


Ces interventions pourraient avoir des effets différents. Le traitement est donc une condition observationnelle opérationnelle. L'interprétation causale exige de supposer qu'une intervention pertinente sur la taille apparente est bien définie.

Une formulation prudente :

Sous les hypothèses d'ajustement et pour cette définition opérationnelle, on estime le contraste associé au passage dans la catégorie très petite.

5. DAG

Version simplifiée :



Le DAG n'est pas une décoration. Il encode les chemins supposés et guide les variables à ajuster.

6. Confounder

Un confounder est une cause commune du traitement et de l'outcome.

Exemple :

- certaines classes sont typiquement petites ;
- la classe influence aussi la facilité de détection.

Chemin non causal :

```

[text]
Taille tres petite <- Classe -> Detection correcte

```

Sans ajuster sur la classe, une mauvaise performance des petits objets pourrait être en partie une différence entre classes.

Reponse orale :

Un confounder cree un chemin arriere entre traitement et outcome. J'ajuste dessus pour comparer des objets plus semblables et bloquer cette association non causale.

7. Mediator

Un mediator est cause par le traitement et transmet une partie de son effet.

Exemple theorique :

```
[text]
Taille tres petite -> Qualite des features -> Detection correcte
```

Si l'objectif est l'effet total de la petite taille, ajuster sur la qualite des features bloquerait une partie de l'effet que l'on veut mesurer.

Le champ difficult peut en partie resumer les consequences de la taille et de la visibilite. Il n'est donc pas inclus automatiquement dans l'ajustement principal.

8. Collider

Un collider est une consequence commune de deux variables :

```
[text]
Taille tres petite -> Selection <- Scene complexe
```

Si on conditionne sur Selection, on peut creer artificiellement une association entre taille et complexite, meme si elles etaient independantes.

Exemple dans le projet :

- une tuile peut etre rejete parce qu'un objet est coupe de facon ambigue ;
- la coupure depend de la position/taille de l'objet et de la grille ;
- analyser seulement des tuiles acceptees peut introduire une selection.

On ne peut pas toujours eliminer ce biais, mais il faut le declarer.

9. Backdoor path

Un backdoor path est un chemin entre D et Y qui commence par une fleche entrant dans D.

Exemple :

```
[text]
D <- Classe -> Y
```

L'ajustement cherche un ensemble de variables qui bloque les backdoors sans bloquer les mediateurs ni ouvrir les colliders.

10. Exemple smoking, cancer et gene

DAG plausible :

```
[text]
Gene -> Smoking -> Cancer
  \-----> Cancer
```

Le gene est un confounder s'il influence a la fois smoking et cancer.

Pour estimer l'effet total de smoking sur cancer, on ajuste sur le gene. On n'ajuste pas sur un mediator cause par smoking si on veut l'effet total.

Si on avait :

```
[text]
Smoking -> Hospitalisation <- Cancer
```

Hospitalisation serait un collider. Conditionner dessus pourrait creer une association trompeuse.

11. Variables d'ajustement du projet

Incluses

- classe ;
- orientation absolue ;
- log du ratio de forme ;
- densité d'objets dans la tuile ;
- source d'image ;
- GSD ;
- marge au bord de tuile ;
- fraction de l'objet conservée.

Non incluse dans l'ajustement principal

- aire exacte, parce qu'elle définit directement le traitement ;
- difficult, car elle peut résumer une conséquence de la petite taille ;
- score de confiance, car il est produit par le détecteur après le traitement ;
- IoU, car elle définit l'outcome ;
- prédictions intermédiaires du réseau, qui sont post-traitement.

12. Hypothèse d'échangeabilité conditionnelle

Forme :

[text]
 $(Y(0), Y(1))$ indépendants de D conditionnellement à X

Intuition :

Après ajustement sur X , le groupe très petit et le groupe contrôle sont comparables quant à leurs outcomes potentiels.

Cette hypothèse ne peut pas être prouvée avec les données. Elle est fragile ici car des variables peuvent manquer :

- contraste local ;
- flou ;
- occultation ;
- conditions de capture ;
- qualité d'annotation ;
- texture du fond.

13. Positivité

Pour chaque combinaison de covariables pertinente :

[text]
 $0 < P(D = 1 \mid X) < 1$

Il faut des objets petits et non petits comparables. Si tous les hélicoptères d'un certain type sont minuscules, leur contrefactuel non petit n'est pas soutenu par les données.

Diagnostic :

- distributions des scores de propension ;
- fraction des scores entre 0.1 et 0.9 ;
- poids extrêmes ;

- effectifs par sous-groupe.

Clipper les scores limite la variance, mais ne crée pas de données manquantes.

14. Coherence et consistance

Si l'objet reçoit effectivement $D=d$, son outcome observé doit correspondre à $Y(d)$.

Cette hypothèse suppose une version assez claire du traitement. Elle est fragile lorsque plusieurs mécanismes différents produisent la même catégorie "très petit".

15. SUTVA et interference

SUTVA suppose notamment que l'outcome d'un objet ne dépend pas du traitement d'un autre objet.

Dans la détection, cette indépendance peut échouer :

- NMS entre objets voisins ;
- occlusion ;
- limite `max_det` dans une tuile dense ;
- contexte partagé.

Le bootstrap par image reconnaît la corrélation statistique entre objets de la même image, mais il ne supprime pas une interference causale.

16. Absence de fuite

Les prédictions causales doivent provenir d'un modèle évalué hors de ses images d'entraînement. Une prédiction sur un objet vu pendant l'entraînement aurait une erreur trop optimiste.

Ici :

- le détecteur est ajusté sur les tuiles d'entraînement ;
- l'outcome est construit sur les tuiles de validation ;
- aucune image source n'est partagée.

17. Difference brute

$$E[Y \mid D=1] - E[Y \mid D=0]$$

Avantage :

- simple et descriptif.

Limite :

- mélange effet du traitement et différences de composition.

Elle reste utile comme point de comparaison. Si l'effet ajusté change beaucoup, les covariables jouaient un rôle important.

18. Regression ajustee et g-computation

On modélise :

$$\mu_d(X) = E[Y \mid D=d, X]$$

Puis on prédit pour chaque objet :

$$\mu_1(X_i) - \mu_0(X_i)$$

et on moyenne.

Avantage :

- produit directement deux outcomes attendus.

Limite :

- biais si le modele d'outcome est mal specifie.

Dans le pipeline, deux forets de classification servent de T-learner : une pour les traites, une pour les controles.

19. Score de propension

[text]
 $e(X) = P(D=1 \mid X)$

Il resume la probabilite d'etre traite compte tenu des covariables.

Le score ne prouve pas que les groupes sont comparables. Il aide a ajuster les variables observees et a diagnostiquer la positivite.

20. IPW

Idee :

- un traite rare dans son profil recoit un poids proche de $1/e(X)$;
- un controle rare recoit un poids proche de $1/(1 - e(X))$.

L'echantillon pondere vise une pseudo-population ou le traitement est moins associe aux covariables.

Limite :

- score proche de 0 ou 1 -> poids enorme -> variance et instabilite.

21. AIPW doublement robuste

Le score AIPW combine modele d'outcome et score de propension :

[text]

$$\begin{aligned} \psi_i = & \mu_1(X_i) - \mu_0(X_i) \\ & + D_i * (Y_i - \mu_1(X_i)) / e(X_i) \\ & - (1-D_i) * (Y_i - \mu_0(X_i)) / (1-e(X_i)) \end{aligned}$$

Intuition :

1. g-computation fournit une prediction de base ;
2. les residus observes corrigent cette prediction ;
3. la correction utilise la probabilite de traitement.

"Doublement robuste" signifie que l'estimateur peut rester coherent si l'un des deux modeles nuisances est correctement specifie, sous les autres hypotheses. Cela ne protege pas contre :

- confounder non observe ;
- mauvaise definition du traitement ;
- absence de positivite ;
- fuite de donnees ;
- selection.

22. Cross-fitting

Si le meme objet sert a entrainer les modeles nuisances et a calculer son pseudo-outcome, un modele flexible peut overfitter.

Le cross-fitting :

1. separe les images en folds ;
2. ajuste les modeles sur les autres folds ;
3. predit sur le fold tenu a l'ecart ;

4. rassemble les predictions hors fold.

Le split est groupe par image source pour ne pas separer des objets fortement lies d'une meme image.

23. Intervalles de confiance

Les objets d'une meme image ne sont pas independants. Un bootstrap objet par objet donnerait trop d'unites independantes.

Le bootstrap groupe :

1. reechantillonne les images avec remise ;
2. prend tous leurs objets ;
3. recalcule la moyenne des scores ;
4. utilise les quantiles 2.5 % et 97.5 %.

Limite du pipeline :

- les modeles nuisances ne sont pas re-ajustes dans chaque repetition, donc

l'incertitude totale peut etre sous-estimee.

24. Effet heterogene

L'ATE peut masquer des differences :

$$\text{CATE}(x) = E[Y(1) - Y(0) \mid X=x]$$

Exemples :

- effet plus negatif dans les scenes denses ;
- effet different selon la classe ;
- effet plus fort pour certaines orientations ;
- effet incertain pour classes rares.

Une heterogeneite estimee n'est pas automatiquement reelle. Chercher beaucoup de sous-groupes augmente le risque de trouver du bruit.

25. Arbre causal honnete

Le pipeline utilise un arbre sur les pseudo-outcomes AIPW :

- moitie des images pour choisir les divisions ;
- autre moitie pour estimer les effets dans les feuilles ;
- profondeur limitee ;
- effectif minimal par feuille.

"Honnete" signifie que les memes observations ne choisissent pas les coupures et n'estiment pas ensuite leurs effets. Cela reduit le biais de selection.

Une feuille de petite taille ou dominee par une seule classe doit etre interpretee prudemment.

26. Foret sur pseudo-outcomes

Plusieurs arbres de regression apprennent ψ_i a partir de X . Le pipeline utilise un split croise par image afin que la CATE d'un objet provienne d'une foret qui n'a pas utilise son image.

Cette methode est une approximation pedagogique d'une foret causale :

- elle utilise un score orthogonal AIPW ;
- elle permet d'explorer l'heterogeneite ;

- elle n'implémente pas toutes les garanties d'un package spécialisé de generalized random forest.

Il faut nommer cette limite, pas présenter l'outil comme magique.

27. Analyse de sensibilité

Le résultat principal dépend de choix :

- IoU 0.50 pour définir une détection correcte ;
- seuil du premier quartile pour "tres petit" ;
- clipping du score de propension ;
- modèle nuisances ;
- sous-ensemble.

Le pipeline varie au moins :

- IoU 0.40, 0.50 et 0.60 ;
- clipping 0.02, 0.05 et 0.10.

Un signe stable renforce la conclusion descriptive sous les hypothèses. Des variations fortes signalent une conclusion fragile.

28. Comment interpréter un effet

Exemple fictif :

```
[text]
ATE AIPW = -0.18
IC 95 % = [-0.25, -0.10]
```

Interprétation prudente :

Sous les hypothèses d'identification, la condition tres petite est associée à une diminution moyenne estimée de 18 points de pourcentage de la probabilité de détection correcte. L'intervalle bootstrap exclut zéro dans ce protocole.

Ne pas dire :

Rendre n'importe quel objet petit fera toujours baisser la détection de 18 %.

L'effet est une différence de probabilité en points de pourcentage, pas nécessairement une baisse relative de 18 %.

29. Liste de limites à savoir expliquer

1. Traitement non randomisé.
2. Variables non observées.
3. Intervention "taille" imparfaitement définie.
4. Sous-ensemble sélectionné.
5. Classes rares et manque de positivité local.
6. Dépendances entre objets d'une image.
7. NMS et interférence possible.
8. Outcome produit par un seul détecteur.
9. Erreurs d'annotation.
10. Sélection due au tuilage et aux fragments.
11. Seuils de confiance et IoU arbitraires mais analysés.
12. Forêt causale approximative.

13. Bootstrap ne re-ajustant pas tous les modeles.
14. Generalisation limitee a la population analysee.

30. Questions de rappel

1. Pourquoi l'outcome potentiel non observe pose-t-il un probleme ?
2. Quelle est la population de l'ATE ici ?
3. Pourquoi la classe peut-elle etre un confounder ?
4. Pourquoi ne pas ajuster sur le score de confiance ?
5. Comment ajuster sur un mediator modifie-t-il l'estimand ?
6. Comment conditionner sur un collider cree-t-il un biais ?
7. Quelle difference entre exchangeabilite et positivite ?
8. Pourquoi le score de propension ne resout-il pas les confounders non observes ?
9. Pourquoi IPW devient-il instable ?
10. Que corrige la partie residuelle de l'AIPW ?
11. Pourquoi le cross-fitting est-il groupe par image ?
12. Pourquoi le bootstrap est-il groupe par image ?
13. Que signifie "honnete" pour l'arbre ?
14. Pourquoi une CATE extreme peut-elle etre du bruit ?
15. Quelle phrase permet d'interpreter un effet sans surpromettre ?

Resultats reels et interpretation defendable

Ce chapitre contient les chiffres finaux du projet. Il faut pouvoir les citer sans les apprendre comme une liste isolée. Pour chaque valeur, savoir répondre à quatre questions :

1. quelle population est mesurée ?
2. quelle définition est utilisée ?
3. quelle conclusion est permise ?
4. quelle limite empêche de généraliser trop vite ?

1. Protocole final en une minute

Le sous-ensemble contient :

- 180 images source pour l'entraînement ;
- 60 images source pour la validation ;
- 15 classes présentes dans les deux splits ;
- 912 tuiles train et 245 tuiles validation ;
- 6 515 annotations tuilées train et 1 972 validation ;
- zero image source commune entre train et validation.

Les images sont découpées en tuiles de 1024 pixels. Le train utilise un stride de 824 pixels et la validation un stride de 1024 pixels. Les fragments conservant au moins 70 % de l'objet sont gardés. Les fragments ambigus entre 20 % et 70 % provoquent le rejet de la tuile concernée.

Trois détecteurs YOLO26n ont été entraînés pendant 20 epochs avec la graine 42 :

- une baseline HBB à 640 ;
- un OBB à 640 ;
- un OBB à 1024.

La validation finale autorise jusqu'à 1 000 détections par tuile. Les métriques globales sont calculées par Ultralytics sur les 245 tuiles. L'outcome causal utilise ensuite un seuil de confiance de 0.25 et une IoU orientée de 0.50.

2. Resultats predictifs globaux

Modele	Precision	Recall	F1	mAP50	mAP50-95	Inference par image
YOLO26n-HBB-640	0.451	0.283	0.347	0.257	0.145	environ 3.0 ms
YOLO26n-OBB-640	0.256	0.299	0.276	0.239	0.146	environ 5.3 ms
YOLO26n-OBB-1024	0.574	0.290	0.385	0.274	0.186	environ 7.6 ms

Calculs a savoir refaire

Gain absolu de mAP50-95 de OBB-1024 par rapport à OBB-640 :

$$[text] \\ 0.186 - 0.146 = 0.040 \text{ point}$$

Gain relatif :

$$[text] \\ (0.186 / 0.146 - 1) \times 100 = \text{environ } 27 \%$$

Par rapport à HBB-640, le gain relatif de mAP50-95 est environ 28 %.

Le coût est une inférence environ 44 % plus lente que OBB-640 :

$$[text] \\ 7.6 / 5.3 - 1 = \text{environ } 0.44$$

Les temps dependent du GPU et de l'etat de la machine. Ils decrivent ce run sur RTX 4060, pas une constante universelle.

Interpretation correcte

OBB-1024 est le meilleur modele de ce protocole selon mAP50-95. Son avantage vient surtout d'une precision plus forte. Son recall reste proche de 0.29 : environ sept objets sur dix ne contribuent donc pas a un rappel correct au point de fonctionnement resume par la metrique globale.

La resolution 1024 aide probablement parce qu'un objet minuscule conserve plus de pixels apres redimensionnement. Ce resultat soutient l'hypothese de resolution, mais il ne permet pas d'affirmer que 1024 sera toujours optimal.

HBB-640 et OBB-640 ont presque la meme mAP50-95. Donc, dans cette experience, conserver l'orientation sans augmenter la resolution n'a pas suffi a creer un gain global clair. Il ne faut pas conclure que les OBB sont inutiles : ils restent geometriquement plus fideles et sont necessaires a l'IoU orientee de l'analyse causale.

3. Resultats par classe

Pour YOLO26n-OBB-1024, les meilleures AP50-95 sont :

Rang	Classe	AP50-95
1	tennis-court	0.544
2	plane	0.384
3	ship	0.325
4	large-vehicle	0.249
5	roundabout	0.232

Les classes les plus faibles sont :

Classe	AP50-95
helicopter	0.000
basketball-court	0.032
soccer-ball-field	0.082
harbor	0.095

Ces differences combinent plusieurs mecanismes :

- nombre d'exemples ;
- taille apparente ;
- contraste ;
- densite de scene ;
- variabilite intra-classe ;
- facilite de localiser precisement la forme ;
- courte duree d'entrainement.

Une AP faible pour helicopter ne prouve pas que la classe est intrinsequement impossible. La validation ne contient que tres peu d'helicopteres et le modele a peu d'information pour apprendre et evaluer cette classe.

Une AP elevee pour tennis-court est plausible parce que la forme est grande, reguliere et visuellement distinctive. Cela reste une explication interpretative, pas une estimation causale de la classe.

4. Taille, orientation et analyse descriptive

Les groupes de taille utilisent les quartiles train. Sur les 1 646 objets validation uniques de la table causale :

Groupe	Objets	Taux de detection correcte
tres petit	623	0.307

Groupe	Objets	Taux de detection correcte
petit	386	0.544
moyen	333	0.456
grand	304	0.536

Le groupe tres petit est clairement le plus faible. En revanche, les quatre groupes ne suivent pas une relation parfaitement monotone. petit depasse moyen et grand dans cette validation. La composition en classes, scenes et orientations change entre groupes. Un tableau descriptif ne maintient pas les autres variables constantes.

La heatmap `detection_by_size_orientation.png` affiche dans chaque case :

- le taux de detection correcte ;
- l'effectif n.

Il faut toujours lire les deux. Par exemple, une case a 0.80 avec peu d'observations est moins stable qu'une case a 0.50 avec plusieurs centaines d'objets.

Le groupe d'orientation 75-90 degres a un taux global eleve, mais il contient beaucoup d'objets et une composition particuliere en classes. Ne pas dire : "une forte orientation ameliore causalement la detection". Ce serait confondre un contraste descriptif avec un effet causal.

5. Construction de la question causale

Traitement D

```
[text]
D = 1 si aire relative de l'objet <= 0.0005035400
```

Le seuil est le premier quartile des objets train uniques. Il represente environ 0.050 % de la surface d'une tuile. Pour une tuile 1024 x 1024, cela correspond a environ 528 pixels carres, soit un carre equivalent d'environ 23 x 23 pixels.

Cette equivalence aide l'intuition. Elle ne transforme pas tous les objets en carres et ne remplace pas l'aire polygonale reelle.

Outcome Y

```
[text]
Y = 1 si une prediction OBB :
- a la meme classe ;
- a une confiance >= 0.25 ;
- a une IoU orientee >= 0.50.
```

Le matching est un-a-un et maximise l'IoU dans chaque classe. Une prediction ne peut donc pas sauver plusieurs objets.

Population et estimand

- 1 646 objets originaux uniques ;
- 53 images source validation contenant ces objets ;
- 623 objets traites, soit 37.8 % ;
- ATE sur la probabilite de detection correcte.

La validation contient 60 images selectionnees, mais 53 contribuent a la table causale finale. Les images sans objet unique eligible ne contribuent pas a cet estimand.

Variables d'ajustement

L'ensemble X contient :

- classe ;
- orientation absolue ;
- log du ratio de forme ;
- densite d'objets dans la tuile ;

- source d'image ;
- GSD ;
- position du centre de l'objet dans la tuile.

L'aire exacte est exclue parce qu'elle définit D. La fraction conservée est exclue de l'ajustement final car elle est liée à la sélection par tuilage et peut se situer après la taille dans le mécanisme étudié. La confiance et l'IoU sont post-traitement ou définissent Y.

6. Contraste observé avant ajustement

Groupe	Objets	Taux Y=1
Tres petit D=1	623	0.307
Contrôle D=0	1 023	0.513

Différence brute :

[text]
 $0.307 - 0.513 = -0.207$

Le groupe très petit a donc environ 20.7 points de pourcentage de détection correcte en moins dans les données observées. Cette différence n'est pas encore un effet causal parce que les groupes diffèrent aussi en classe, GSD, densité et autres covariables.

7. Estimateurs causaux comparés

Méthode	Effet	IC 95 % bootstrap image
Différence brute	-0.207	[-0.520 ; 0.052]
G-computation	-0.170	[-0.260 ; -0.096]
IPW	-0.620	[-0.860 ; -0.352]
AIPW doublement robuste	-0.368	[-0.530 ; -0.166]

Phrase principale à apprendre

Sous les hypothèses d'identification, la condition très petite est associée à une diminution moyenne estimée de 36.8 points de pourcentage de la probabilité de détection correcte. L'intervalle bootstrap groupe à 95 % est [-53.0 ; -16.6] points et exclut zéro dans la spécification principale.

Le mot associée rappelle que le traitement n'est pas randomisé. Le mot moyenne rappelle qu'il s'agit d'un ATE dans la population analysée. Le mot points évite de confondre différence absolue et baisse relative.

Pourquoi les quatre valeurs différent-elles ?

- la différence brute ne rend pas les groupes comparables ;
- la g-computation dépend des modèles d'outcome ;
- l'IPW dépend fortement des inverses de propension ;
- l'AIPW combine outcome et propension avec une correction résiduelle.

L'IPW très négatif et l'écart entre estimateurs signalent une fragilité de support ou de modélisation. Il serait incorrect de dire que l'AIPW "révèle la vérité". Il fournit l'estimation principale selon le protocole choisi.

8. Positivité et propension

La part des objets dont la propension tronquée est entre 0.10 et 0.90 vaut 76.5 %. Cela montre un recouvrement réel, mais imparfait.

Détails utiles :

- 205 objets atteignent la borne basse 0.05 ;
- 42 objets atteignent la borne haute 0.95 ;

- mediane de propension chez D=0 : 0.251 ;
- mediane de propension chez D=1 : 0.625.

Les profils traites et controles restent donc differents. Le clipping evite des poids infinis, mais change aussi l'estimand pratique et introduit un compromis biais-variance.

9. Analyse de sensibilité

Specification	Effet AIPW	IC 95 %
IoU >= 0.40	-0.374	[-0.518 ; -0.190]
IoU >= 0.50	-0.368	[-0.519 ; -0.183]
IoU >= 0.60	-0.332	[-0.480 ; -0.141]
Clipping 0.02	-0.274	[-0.507 ; 0.085]
Clipping 0.10	-0.388	[-0.504 ; -0.246]
Graine nuisances 7	-0.370	[-0.535 ; -0.155]
Graine nuisances 99	-0.366	[-0.522 ; -0.177]

Le signe reste negatif dans toutes les estimations ponctuelles. Les seuils IoU et les graines des modeles nuisances donnent des amplitudes proches.

La specification de clipping 0.02 produit toutefois un intervalle qui traverse zero. C'est important : la conclusion ponctuelle est stable en signe, mais la force inferentielle depend du traitement des propensions extremes. Cette nuance doit apparaitre dans une bonne presentation orale.

10. Arbre causal honnete

L'arbre est volontairement conservateur :

- une moitie des images choisit une seule division ;
- chaque feuille de structure doit etre grande ;
- l'autre moitie estime les effets des feuilles ;
- les intervalles reechantillonnent les images.

La division choisie est :

```
[text]
nombre d'objets dans la tuile <= 16.5
```

Resultats sur la moitie holdout :

Sous-groupe	Objets	Images	Effet	IC 95 %
Densite <= 16.5	296	20	-0.131	[-0.640 ; 0.474]
Densite > 16.5	795	12	-0.457	[-0.646 ; -0.221]

L'effet semble plus negatif dans les tuiles denses. Le sous-groupe dense ne contient cependant que 12 images source malgre 795 objets. Il ne faut donc pas transformer cette coupure en loi universelle. Elle constitue une hypothese d'heterogeneite a verifier sur davantage d'images.

Le mot honnete ne veut pas dire que le resultat est certainement vrai. Il veut dire que les observations choisissant la coupure ne servent pas ensuite a estimer l'effet de cette meme coupure.

11. Foret sur pseudo-outcomes

La foret predit une CATE a partir des scores AIPW dans des folds groupes par image. Les predictions sont projetees dans $[-1, 1]$, les bornes logiques d'un effet sur un outcome binaire.

Resume de la distribution :

- mediane environ -0.258 ;

- premier quartile environ -0.418 ;
- troisième quartile environ -0.132 ;
- 5e percentile environ -0.906 ;
- 95e percentile environ 0.287.

Cette forêt est une approximation pédagogique d'une forêt causale spécialisée. Les valeurs individuelles ne doivent pas être présentées comme des effets personnels vrais. Elles servent à visualiser une hétérogénéité possible.

12. Ce qui est prédictif et ce qui est causal

Énoncé	Type	Statut
OBB-1024 a mAP50-95 0.186	Prédictif	Mesure directe du protocole
tennis-court a la meilleure AP	Prédictif	Mesure par classe
Les très petits ont un taux observé de 0.307	Descriptif	Association brute
AIPW vaut -0.368	Causal sous hypothèses	Estimation ajustée
L'effet semble plus fort en scène dense	Hétérogénéité causale exploratoire	À confirmer

Un modèle peut avoir une bonne AP pour tennis-court tout en ne répondant pas à la question : "quel est l'effet d'être très petit ?". La mAP intègre localisation et classification. L'ATE compare des résultats potentiels sous deux conditions de taille, avec des hypothèses d'identification.

13. Figures : ordre de lecture

[model_comparison.png](#)

1. identifier le meilleur mAP50-95 ;
2. comparer précision et rappel ;
3. noter que F1 est dans le tableau global ;
4. rappeler le coût d'inférence de 1024.

[per_class_metrics.png](#)

1. regarder les écarts de classe ;
2. ne pas ignorer les classes rares ;
3. comparer HBB/OBB sans généraliser hors protocole.

[prediction_examples_yolo26n-obb-1024.jpg](#)

1. voir les OBB et confiances ;
2. repérer les tuiles sans prédiction ;
3. relier ces faux négatifs au rappel modeste.

[detection_by_size_orientation.png](#)

1. lire le taux ;
2. lire l'effectif n ;
3. rappeler que la heatmap est descriptive.

[causal_effects.png](#)

1. lire le signe ;
2. comparer les estimateurs ;
3. vérifier si l'intervalle traverse zéro ;
4. remarquer la dispersion IPW/AIPW.

propensity_overlap.png

1. vérifier qu'il existe du support commun ;
2. repérer les masses aux bornes 0.05 et 0.95 ;
3. expliquer pourquoi le clipping est nécessaire mais pas gratuit.

causal_tree.png

1. distinguer moitié structure et moitié holdout ;
2. lire le seuil de densité ;
3. comparer effets, intervalles et nombre d'images ;
4. conclure exploratoire.

14. Réponse orale de deux minutes

J'ai d'abord séparé les images DOTA au niveau source avant tout tuilage afin d'éviter une fuite entre tuiles proches. Sur 180 images train et 60 validation, j'ai entraîné trois YOLO26n pendant 20 époques. Le meilleur est YOLO26n-OBB à 1024 avec une mAP50-95 de 0.186, contre environ 0.146 pour les deux modèles 640. Son recall reste toutefois modeste, environ 0.29, et les performances varient fortement par classe. La question causale est différente : quel est l'effet d'être très petit sur la probabilité d'une détection OBB correcte ? Le traitement utilise le premier quartile d'aire train et l'outcome exige même classe, confiance 0.25 et IoU orientée 0.50. Sur 1 646 objets uniques de 53 images, le taux observé est 0.307 chez les très petits contre 0.513 chez les contrôles. Après ajustement et cross-fitting groupe par image, l'AIPW principal estime -0.368, avec un intervalle bootstrap [-0.530 ; -0.166]. Les sensibilités restent négatives en valeur ponctuelle, mais le clipping 0.02 donne un intervalle traversant zéro. L'arbre honnête suggère un effet plus négatif dans les tuiles denses, mais ce sous-groupe ne contient que 12 images. Je présente donc un signal cohérent mais observationnel, limité par la positivité, les confounders non observés, le sous-ensemble et la définition imparfaite d'une intervention sur la taille.

15. Phrases interdites et corrections

Mauvais :

OBB est toujours meilleur que HBB.

Correct :

OBB-1024 obtient la meilleure mAP50-95 dans ce protocole ; OBB-640 et HBB-640 sont presque égaux.

Mauvais :

Les petits objets causent exactement 36.8 % d'erreurs en plus.

Correct :

Sous les hypothèses d'identification, l'effet moyen AIPW est une baisse estimée de 36.8 points de probabilité, avec incertitude et sensibilité.

Mauvais :

L'arbre prouve que la densité est la cause.

Correct :

L'arbre suggère une hétérogénéité selon la densité ; la division est exploratoire et repose sur peu d'images dans une feuille.

Mauvais :

L'intervalle principal exclut zéro, donc aucun biais n'est possible.

Correct :

L'intervalle quantifie l'incertitude d'échantillonnage du score dans ce protocole ; il ne couvre pas les confounders non observés ni toutes les décisions de modélisation.

16. Grille de memorisation

Compléter sans regarder :

Element	Valeur a connaître
Images train / validation	
Tuiles train / validation	
Meilleur modele	
mAP50-95 du meilleur modele	
Recall du meilleur modele	
Nombre d'objets causaux	
Nombre d'images causales	
Seuil tres petit	
Taux Y traite / controle	
AIPW et IC	
Recouvrement 0.1-0.9	
Coupure de l'arbre	
Effet de la feuille dense	
Sensibilite qui traverse zero	

Si une valeur est oubliée, ne pas inventer. Revenir au tableau correspondant et reconstruire son sens.

Exercices sans corrige

Ne pas ouvrir 07_corrige.md avant d'avoir écrit ou prononcé une réponse.

Detection

D1 - IoU

Deux boîtes de surface 120 et 80 ont une intersection de surface 50.

1. Calculer l'union.
2. Calculer l'IoU.
3. Dire si la detection passe un seuil IoU de 0.50.

D2 - Deux boîtes pour un objet

Un objet reel plane recoit deux predictions plane :

- A : confiance 0.92, IoU 0.72 ;
- B : confiance 0.70, IoU 0.66.

Expliquer :

1. pourquoi les deux predictions ne doivent pas devenir deux TP ;
2. le role possible de la NMS ;
3. ce qui peut arriver a B apres le matching.

D3 - Matrice de confusion de detection

Un modele produit 80 detections. Parmi elles, 52 sont des TP. Le dataset contient 65 objets reels.

1. Calculer FP.
2. Calculer FN.
3. Calculer precision.
4. Calculer recall.
5. Calculer F1.

D4 - Seuil de confiance

On augmente le seuil de confiance de 0.20 a 0.70.

1. Quel mouvement general attend-on pour precision ?
2. Quel mouvement general attend-on pour recall ?
3. Pourquoi ce n'est pas une loi absolue sur chaque petit echantillon ?

D5 - mAP

Expliquer sans formule :

1. AP ;
2. mAP ;
3. mAP50 ;
4. mAP50-95 ;
5. pourquoi il faut aussi AP par classe.

D6 - HBB et OBB

Dessiner un rectangle diagonal long et fin.

1. Dessiner sa HBB.
2. Dessiner son OBB.
3. Comparer la quantité de fond.
4. Expliquer un effet possible sur IoU et NMS.
5. Donner une raison pour laquelle OBB pourrait quand même moins bien scorer dans une expérience courte.

D7 - Petite erreur, grand effet

Un petit objet mesure environ 8 x 8 pixels. La prédiction est décalée de 4 pixels. Un grand objet mesure 160 x 160 pixels et subit le même décalage.

Expliquer qualitativement pourquoi l'IoU du petit objet est plus affectée.

D8 - Loss et métrique

Repondre à l'affirmation :

La loss train a baissé, donc le modèle final est forcément meilleur.

Donner au moins trois raisons pour lesquelles cette conclusion est insuffisante.

Pipeline et données

P1 - Fuite par tuiles

Une image DOTA est découpée en 30 tuiles. On mélange les 30 tuiles, puis on en place 24 en train et 6 en validation.

1. Identifier la fuite.
2. Expliquer pourquoi la validation devient optimiste.
3. Proposer le bon ordre des opérations.

P2 - Positions de grille

Une dimension d'image vaut 2500 pixels, la tuile 1024 et le stride 824.

1. Les deux premières positions sont 0 et 824.
2. Calculer la position finale qui couvre exactement le bord.
3. Expliquer pourquoi elle ne suit pas forcément le stride.
4. Dire si un chevauchement final existe.

P3 - Fragments

Classer les cas :

- objet conserve à 95 % ;
- objet conserve à 75 % ;
- objet conserve à 45 % ;
- objet conserve à 10 %.

Utiliser les seuils 0.70 et 0.20 du pipeline et expliquer chaque décision.

P4 - Tuiles négatives

1. Pourquoi ne pas supprimer toutes les tuiles négatives ?
2. Pourquoi ne pas garder toutes les tuiles négatives ?
3. Quel type d'erreur est directement concerné ?

P5 - Stratification

La selection couvre les 15 classes et combine classe dominante et densite.

1. Pourquoi est-ce mieux qu'un simple tirage aleatoire ?
2. Pourquoi cela ne resout-il pas completement le desequilibre ?
3. Pourquoi la validation ne doit-elle pas etre artificiellement equilibree

sans explication ?

P6 - Objet duplique

Un objet apparait dans deux tuiles train chevauchantes.

1. Est-ce une fuite train-validation ?
2. Pourquoi faut-il quand meme le tracer ?
3. Pourquoi l'analyse causale choisit-elle une seule instance ?

P7 - Reproductibilite

Donner au moins huit elements a enregistrer pour reproduire un run.

P8 - Comparaison equitable

On compare :

- HBB initialise avec COCO ;
- OBB initialise avec un poids deja ajuste sur DOTA.

Expliquer le probleme et proposer un protocole plus equitable.

Causalite

C1 - Smoking, gene, cancer

Construire un DAG ou :

- le gene influence smoking ;
- le gene influence cancer ;
- smoking influence cancer.

1. Quel est le traitement ?
2. Quel est l'outcome ?
3. Quel est le confounder ?
4. Sur quoi faut-il ajuster pour l'effet total de smoking ?

C2 - Confounder DOTA

Utiliser classe, tres petit et detection correcte.

1. Construire un backdoor path.
2. Expliquer le biais sans ajustement.
3. Expliquer ce que l'ajustement essaie de faire.

C3 - Mediator

Proposer un mediator entre petite taille et detection. Expliquer pourquoi l'ajuster ne donne plus l'effet total.

C4 - Collider

Construire un collider avec petite taille, scene complexe et tuile selectionnee. Expliquer pourquoi conditionner sur la selection peut ouvrir un chemin.

C5 - Variables post-traitement

Classer ces variables comme ajustement plausible ou variable à éviter dans le modèle principal :

- classe ;
- orientation ;
- score de confiance ;
- IoU ;
- source ;
- GSD ;
- feature interne du détecteur ;
- densité ;
- aire exacte lorsque le traitement est défini par l'aire.

C6 - Outcomes potentiels

Pour un objet donné, définir $Y(1)$ et $Y(0)$. Expliquer pourquoi les deux ne sont jamais observés ensemble.

C7 - Hypotheses

Donner une définition intuitive et une menace DOTA pour :

1. échangeabilité conditionnelle ;
2. positivité ;
3. cohérence ;
4. absence d'interférence ;
5. absence de fuite.

C8 - Difference brute

Taux de détection :

- très petits : 0.18 ;
 - contrôles : 0.43.
1. Calculer la différence brute.
 2. L'exprimer en points de pourcentage.
 3. Expliquer pourquoi elle n'est pas automatiquement causale.

C9 - Score de propension

Deux objets ont des scores 0.03 et 0.52.

1. Lequel a le meilleur support commun ?
2. Pourquoi le premier peut créer un poids extrême ?
3. Que fait le clipping ?
4. Quelle limite le clipping ne résout-il pas ?

C10 - IPW

Un objet traité a $e(X)=0.20$.

1. Quel est son poids IPW non stabilisé ?
2. Pourquoi un traité avec faible propension reçoit-il un grand poids ?
3. Quel est le danger ?

C11 - AIPW

Expliquer les deux sources d'information combinées par AIPW. Définir "doublement robuste" sans dire "toujours sans biais".

C12 - Cross-fitting

1. Pourquoi ne pas prédire les nuisances sur les mêmes objets qui les ont entraînées ?

2. Pourquoi grouper par image ?

3. Quelle ressemblance avec une prédiction hors échantillon ?

C13 - Arbre causal honnête

1. Quelle moitié choisit les divisions ?

2. Quelle moitié estime les effets des feuilles ?

3. Pourquoi séparer ?

4. Pourquoi limiter profondeur et taille minimale ?

C14 - Sensibilité

Le signe AIPW est négatif à IoU 0.40, 0.50 et 0.60, mais l'amplitude double à 0.60.

1. Quelle partie est stable ?

2. Quelle partie est sensible ?

3. Quelle conclusion prudente donner ?

Analyse des sorties réelles

Ces exercices utilisent les fichiers dans `outputs/analysis/`.

R1 - Comparaison globale

Ouvrir `model_comparison.csv`.

1. Quel modèle a la meilleure mAP50 ?

2. Quel modèle a la meilleure mAP50-95 ?

3. Quel est le gain ou la perte absolue ?

4. La résolution 1024 aide-t-elle ?

5. Proposer deux explications et une limite.

R2 - Classes

Ouvrir `per_class_metrics.csv`.

1. Identifier les trois meilleures et trois pires classes du modèle retenu.

2. Comparer avec les comptes de `class_coverage.csv`.

3. Donner un cas où fréquence et AP ne suivent pas exactement la même tendance.

R3 - Taille et orientation

Ouvrir `detection_by_size_orientation.png`.

1. Quel groupe semble le plus difficile ?

2. Les différences sont-elles monotones ?

3. Quels effectifs faudrait-il vérifier avant de conclure ?

R4 - Effet moyen

Ouvrir `causal_effect_estimates.csv`.

1. Comparer brut, g-computation, IPW et AIPW.
2. Le signe est-il stable ?
3. L'IC AIPW inclut-il zero ?
4. Ecrire une interpretation correcte en deux phrases.

R5 - Positivite

Ouvrir `propensity_overlap.png`.

1. Les distributions se chevauchent-elles ?
2. Y a-t-il des zones presque sans controles ou traites ?
3. Quelle consequence pour la variance et la generalisation ?

R6 - Heterogeneite

Ouvrir `causal_tree_subgroups.csv` et `cate_distribution.png`.

1. Quelle feuille a l'effet le plus negatif ?
2. Combien d'images et d'objets contient-elle ?
3. Quelle variable semble structurer les effets ?
4. Pourquoi ne faut-il pas transformer cette feuille en loi generale ?

Mini-examen final

Temps conseille : 35 minutes, sans documents.

1. Dessiner le pipeline complet.
2. Définir IoU, precision, recall, AP et mAP.
3. Expliquer le choix OBB.
4. Expliquer le risque de fuite par tuile.
5. Justifier le sous-ensemble stratifié.
6. Définir D, Y, X et ATE.
7. Dessiner le DAG DOTA principal.
8. Distinguer confounder, mediator et collider.
9. Expliquer exchangeabilite et positivite.
10. Comparer difference brute, g-computation, IPW et AIPW.
11. Expliquer cross-fitting et bootstrap groupe.
12. Expliquer arbre causal honnete.
13. Donner les resultats reels principaux.
14. Donner cinq limites.
15. Conclure en 90 secondes sans confondre prediction et causalite.

Questions orales avec reponses courtes

Lire seulement la question, repondre, puis reveler la reponse.

Projet et donnees

1. Quel est l'objectif du projet ?

Detecter et classifier des objets dans des images DOTA, puis estimer si la condition tres petite affecte la probabilite de detection correcte. La premiere partie est predictive, la seconde causale.

2. Pourquoi DOTA est-il difficile ?

Les images sont grandes, les objets varient fortement en taille, peuvent etre minuscules, denses et orientes, et les 15 classes sont desequilibrees.

3. Que contient une annotation DOTA ?

Quatre coins, donc huit coordonnees, une classe et un indicateur `difficult`. Le fichier contient aussi des metadonnees comme la source et parfois le GSD.

4. Pourquoi tuiler ?

Les images completes sont trop grandes pour un detecteur standard et les petits objets seraient fortement reduits. Les tuiles rendent le calcul faisable et preservent davantage de pixels par objet.

5. Quel est le principal risque du tuilage ?

La fuite si des tuiles d'une meme image source sont reparties entre train et validation. Le split doit etre fait au niveau de l'image avant le tuilage.

6. Pourquoi 1024 pixels ?

C'est un compromis entre contexte, preservation des petits objets, nombre de fragments et memoire GPU. Ce n'est pas une valeur universelle.

7. Pourquoi un chevauchement en train ?

Il augmente les chances qu'un objet proche du bord soit entier dans une autre tuile et enrichit les positions vues pendant l'apprentissage.

8. Pourquoi moins de chevauchement en validation ?

Pour eviter une evaluation trop redondante et ne pas compter plusieurs fois les memes objets. Une instance unique est ensuite gardees pour la causalite.

9. Pourquoi garder des tuiles negatives ?

Elles apprennent au modele a reconnaitre le fond et reduisent les fausses alertes. Toutes les garder ferait dominer le fond et couterait trop cher.

10. Que signifie stratifier ici ?

Selectionner des images en preservant la couverture des classes et des types de scene definis par classe dominante et densite, plutot que tirer aveuglement.

Detection et YOLO

11. Detection ou classification ?

La classification donne surtout une classe globale. La detection donne plusieurs classes et leurs localisations dans la meme image.

12. HBB ou OBB ?

HBB est alignee aux axes. OBB tourne avec l'objet. OBB correspond mieux aux annotations et objets orientes de DOTA.

13. Pourquoi garder HBB ?

Elle fournit une baseline simple sur exactement les memes tuiles et permet de quantifier ce que change la representation orientee.

14. Qu'est-ce que l'loU ?

Le rapport entre l'aire d'intersection et l'aire d'union des boites. Elle mesure la qualite geometrique de la localisation entre 0 et 1.

15. Quand une prediction est-elle un TP ?

Quand elle est associee a un objet reel, a la bonne classe, avec un score suffisant et une loU au-dessus du seuil choisi.

16. Difference FP/FN ?

FP est une alerte non correcte. FN est un objet reel manque. Une mauvaise classification peut produire les deux simultanement.

17. Precision ?

Parmi les detections annoncees, proportion correcte : $TP / (TP + FP)$.

18. Recall ?

Parmi les objets reels, proportion retrouvee : $TP / (TP + FN)$.

19. AP ?

Aire sous la courbe precision-recall d'une classe quand le seuil de confiance varie.

20. mAP ?

Moyenne des AP sur les classes. Elle resume le detecteur, mais doit etre completee par les scores par classe et sous-groupe.

21. mAP50 contre mAP50-95 ?

mAP50 utilise un seuil loU 0.50. mAP50-95 moyenne plusieurs seuils jusqu'a 0.95 et exige une localisation plus precise.

22. Score de confiance ?

Valeur utilisee pour classer et filtrer les detections. Elle n'est ni une garantie de justesse ni une mesure directe de l'loU.

23. NMS ?

Post-traitement qui garde une boite forte et supprime des boites redondantes trop chevauchantes. Elle peut supprimer de vrais voisins en scene dense.

24. Backbone ?

Partie qui extrait les caracteristiques visuelles des pixels, des motifs simples jusqu'aux representations plus semantiques.

25. Neck ?

Partie qui combine les features de plusieurs echelles, importante pour detecter a la fois grands terrains et petits vehicules.

26. Head ?

Partie qui transforme les features en classes, scores et boites. La head OBB represente aussi l'orientation.

27. Que minimise YOLO ?

Une loss combinant erreurs de localisation, classification et autres composantes, avec une composante d'angle dans OBB.

28. Loss contre mAP ?

La loss guide l'optimisation sur train. La mAP évalue les détections sur validation. Une loss plus basse ne garantit pas une meilleure mAP.

29. Transfert learning ?

Partir d'un backbone pré-entraîné sur COCO puis l'ajuster sur DOTA. Cela économise données et temps par rapport à un départ aléatoire.

30. Pourquoi les memes poids de depart ?

Pour comparer HBB et OBB sans donner à OBB l'avantage de poids déjà ajustés sur DOTA.

31. Pourquoi les petits objets sont-ils difficiles ?

Peu de pixels, perte au redimensionnement, bruit de fond, densité et forte sensibilité de l'IoU à quelques pixels d'erreur.

32. Pourquoi augmenter imgsiz ?

Le réseau voit davantage de pixels par petit objet. En contrepartie, le calcul et la mémoire augmentent et le batch doit parfois diminuer.

33. Overfitting ?

Le modèle s'améliore sur train mais ne généralise plus : validation stagne ou baisse. On examine les courbes et utilise notamment l'early stopping.

34. Pourquoi AP par classe ?

La moyenne peut cacher une classe rare presque jamais détectée ou une classe fréquente très facile.

Causalite

35. Correlation contre causalite ?

La corrélation décrit une différence observée. La causalité compare ce qui arriverait sous deux conditions contrefactuelles, avec des hypothèses d'identification.

36. Traitement retenu ?

Être dans le premier quartile d'aire relative de tuile, seuil défini sur les objets train uniques.

37. Outcome retenu ?

Une prédiction OBB de même classe, confiance au moins 0.25 et IoU au moins 0.50 sur la validation.

38. ATE ?

Moyenne de $Y(1) - Y(0)$ dans la population d'objets analysée. Ici, une différence de probabilité de détection correcte.

39. Confounder ?

Cause commune du traitement et de l'outcome. La classe peut influencer taille typique et facilité de détection.

40. Mediator ?

Variable causée par le traitement qui transmet son effet. L'ajuster bloque une partie de l'effet total.

41. Collider ?

Conséquence commune de deux variables. Conditionner dessus peut ouvrir une association artificielle.

42. Backdoor path ?

Chemin non causal entre traitement et outcome qui commence par une flèche entrant dans le traitement, par exemple $D \leftarrow \text{classe} \rightarrow Y$.

43. Pourquoi ne pas ajuster sur l'aire exacte ?

Elle définit directement le traitement très petit. L'inclure rendrait les groupes presque déterministes et ne correspondrait pas à l'ajustement retenu.

44. Pourquoi ne pas ajuster sur la confiance ?

La confiance est produite après le traitement par le détecteur et participe à la définition de l'outcome. C'est une variable post-traitement.

45. Exchangeabilité ?

Après ajustement sur X, les groupes seraient comparables quant aux outcomes potentiels. Elle est non testable et menacée par le flou ou contraste non observé.

46. Positivité ?

Pour chaque profil, il faut une probabilité non nulle d'être traité et contrôlé. Des classes toujours minuscules violent localement cette hypothèse.

47. Coherence ?

L'outcome observé sous le traitement reçu correspond à l'outcome potentiel de ce traitement. Elle demande une version suffisamment bien définie de "petit".

48. Interference ?

L'outcome d'un objet pourrait dépendre d'autres objets via NMS, occlusion ou `max_det`. Cela fragilise l'indépendance entre unités.

49. Difference brute ?

Taux moyen traité moins taux moyen contrôlé. Simple mais confondu par les différences de composition.

50. G-computation ?

Modéliser l'outcome sous $D=1$ et $D=0$ pour chaque X, calculer les deux prédictions et moyenner leur différence.

51. Score de propension ?

Probabilité de traitement conditionnelle aux covariables. Il sert à ajuster et diagnostiquer le support, pas à supprimer les confounders non observés.

52. IPW ?

Pondérer les objets par l'inverse de la probabilité de leur traitement observé. Les scores extrêmes rendent l'estimation instable.

53. AIPW ?

Combine modèle d'outcome et propension, puis corrige les prédictions avec des résidus pondérés. Double robustesse ne signifie pas absence de toutes limites.

54. Cross-fitting ?

Les nuisances d'un objet sont prédites par des modèles qui n'ont pas utilisé son fold. Les folds sont groupés par image pour limiter l'overfitting et la dépendance.

55. Pourquoi bootstrap par image ?

Les objets d'une même image partagent contexte et conditions. Les rééchantillonnages comme indépendants donneraient une incertitude trop petite.

56. Arbre causal honnête ?

Une partie des images choisit les divisions, l'autre estime les effets des feuilles. Cela limite le biais de recherche de sous-groupes.

57. CATE ?

Effet moyen conditionnel a un profil X. Il sert a etudier l'heterogeneite, mais les estimations extremes demandent de grands effectifs et validation.

58. Sensibilite ?

Refaire l'estimation avec d'autres seuils raisonnables, par exemple IoU ou clipping, pour voir si signe et amplitude dependent d'un choix arbitraire.

59. Pourquoi le resultat reste-t-il prudent ?

Le traitement n'est pas randomise, des confounders manquent peut-etre, la selection et l'interference existent, et la population est un sous-ensemble.

60. Conclusion type ?

Le detecteur fournit des performances predictives mesurees sur validation. La partie causale estime ensuite un contraste sur les erreurs, sous des hypotheses fortes. Les deux reponses sont complementaires mais non interchangeables.

Corrige des exercices

Detection

D1

```
[text]
union = 120 + 80 - 50 = 150
IoU = 50 / 150 = 0.333
```

La detection ne passe pas le seuil 0.50.

D2

Une prediction ne peut valider qu'un objet et un objet ne doit recevoir qu'un TP. La NMS peut supprimer B avant l'evaluation si les deux boites se chevauchent assez. Sinon le matching associe normalement A a l'objet et B reste non associee, donc peut compter comme FP.

D3

```
[text]
FP = 80 - 52 = 28
FN = 65 - 52 = 13
precision = 52 / 80 = 0.650
recall = 52 / 65 = 0.800
F1 = 2 * 0.65 * 0.80 / (0.65 + 0.80) = 0.717
```

D4

En general, precision monte et recall baisse parce que moins de predictions sont gardees. Sur un petit echantillon, la composition et l'ordre des scores peuvent produire des variations non monotones de certaines statistiques.

D5

- AP : resume la courbe precision-recall d'une classe.
- mAP : moyenne les AP des classes.
- mAP50 : matching avec seuil IoU 0.50.
- mAP50-95 : moyenne plusieurs seuils, donc localisation plus exigeante.
- AP par classe : revele les classes cachees par la moyenne.

D6

La HBB contient plus de fond autour du rectangle diagonal. L'OBB suit son axe. La HBB peut augmenter le chevauchement avec le fond et des voisins, degrader la precision geometrique et rendre la NMS plus confuse. OBB peut quand meme moins bien scorer si la tete orientee, plus complexe, est sous-entrainee ou si la metrique orientee est plus stricte.

D7

Le decalage represente la moitie de la largeur du petit objet mais seulement 2.5 % de celle du grand. La fraction d'intersection chute donc beaucoup plus pour le petit objet.

D8

Il faut verifier validation, pas seulement train. La loss n'est pas la mAP, un overfitting est possible, les classes peuvent reagir differemment, et le checkpoint a meilleure validation peut precéder la dernière époque.

Pipeline

P1

Les tuiles partagent le meme paysage et parfois des objets. La validation reconnait des motifs déjà vus. Il faut d'abord repartir les images sources, puis tuiler chaque split separement.

P2

```
[text]
position finale = 2500 - 1024 = 1476
```

Les positions sont $[0, 824, 1476]$. La dernière est forcée pour couvrir le bord et chevauche la tuile précédente de $824 + 1024 - 1476 = 372$ pixels.

P3

- 95 % : garde ;
- 75 % : garde ;
- 45 % : zone ambiguë, tuile rejetée ;
- 10 % : fragment ignoré.

P4

Les négatives enseignent le fond et réduisent les FP. Toutes les garder ferait dominer le train par le fond. L'erreur directement concernée est le faux positif.

P5

La stratification augmente la couverture des classes et scènes. Elle ne crée pas d'exemples pour une classe vraiment rare et ne garantit pas des comptes égaux. Une validation artificiellement équilibrée ne représenterait plus la population sans une définition explicite de la métrique cible.

P6

Ce n'est pas une fuite si les deux tuiles restent train. La duplication change le poids de l'objet dans la loss et doit être tracée. En causalité, garder deux instances donnerait plus de poids à certains objets et violerait l'unité d'analyse.

P7

Exemples : code, données/split, graine, versions Python/PyTorch/Ultralytics, GPU/CUDA, poids de départ, architecture, epochs, batch, taille d'image, optimiseur, patience, augmentations, seuils, checkpoint et temps.

P8

OBB bénéficie d'une information spécifique à DOTA avant l'expérience. Il faut partir du même pré-entraînement général, ici COCO, et ajuster chaque tête sur les mêmes tuiles avec le même split et la même graine.

Causalité

C1

```
[text]
Gene -> Smoking -> Cancer
      \-----> Cancer
```

Traitement : smoking. Outcome : cancer. Confounder : gene. Pour l'effet total, ajuster sur gene sous les hypothèses du DAG.

C2

```
[text]
Tres petit <- Classe -> Detection correcte
```

Les classes ont des tailles et difficultés différentes. Sans ajustement, leur composition contamine la comparaison. L'ajustement compare des objets ayant des profils de classe et autres covariables plus semblables.

C3

Exemple : qualité des features extraites. Petite taille réduit l'information, qui influence la détection. Ajuster dessus retire ce chemin et vise plutôt un effet direct.

C4

```
[text]
Petite taille -> Tuile selectionnee <- Scene complexe
```

Conditionner sur la selection peut rendre petite taille et complexite associees dans l'echantillon retenu, ouvrant un chemin vers l'outcome.

C5

Ajustements plausibles : classe, orientation, source, GSD, densite. A eviter : confiance, IoU et feature interne car post-traitement/outcome ; aire exacte car elle definit D dans ce protocole.

C6

$Y(1)$ est la detection si l'objet etait tres petit, $Y(0)$ s'il ne l'etait pas. L'objet n'a qu'une condition observee ; l'autre est contrefactuelle.

C7

- Exchangeabilite : pas de confounding residuel apres X ; menace par flou non observe.
- Positivite : les deux traitements possibles pour chaque profil ; menace par classes toujours petites.
- Coherence : version de D suffisamment definie ; menace par plusieurs mecanismes de petitesse.
- Interference : un objet n'affecte pas l'autre ; menace par NMS.
- Absence de fuite : outcome hors train ; menace par tuiles de meme source.

C8

```
[text]
0.18 - 0.43 = -0.25
```

Difference de 25 points de pourcentage. Elle peut refleter classe, GSD, orientation ou densite, pas seulement la taille.

C9

0.52 a un meilleur support. A 0.03, un traite aurait un poids environ 33.3. Le clipping borne le poids et la variance, mais ne fabrique pas de controles comparables et ne corrige pas les confounders non observes.

C10

Poids $1/0.20 = 5$. L'objet represente plusieurs profils similaires parce que son traitement est rare. Des poids trop grands rendent l'estimation dominee par quelques observations.

C11

AIPW combine predictions d'outcome et propension, puis utilise les residus pour corriger. Double robustesse couvre une mauvaise specification de l'un des deux modeles sous conditions, pas les variables omises ou la mauvaise positivite.

C12

Les predictions in-sample overfittent et donnent des pseudo-outcomes biaises. Grouper par image evite que des objets partageant le meme contexte traversent les folds. C'est une logique hors echantillon.

C13

La moitie structure choisit les divisions, la moitie estimation mesure les feuilles. Cela evite d'utiliser le meme bruit deux fois. Faible profondeur et grandes feuilles reduisent variance et decouvertes artificielles.

C14

Le signe négatif est stable. L'amplitude dépend du niveau d'exigence géométrique. Conclusion : la pénalité semble robuste en direction, mais sa taille exacte est sensible à la définition de l'outcome.

Sorties réelles

Les réponses R1 à R6 changent avec les runs. Elles doivent être calculées directement depuis `outputs/analysis/`. La bonne correction est une réponse qui cite :

- la valeur exacte ;
- le dénominateur ou l'effectif ;
- l'incertitude ;
- une explication plausible ;
- au moins une limite.

Grille du mini-examen

Attribuer 2 points par item :

- 0 : absent ou faux ;
- 1 : idée correcte mais incomplète ;
- 2 : définition, lien DOTA et limite.

Score maximal : 30.

- 26-30 : solide ;
- 21-25 : défendable, quelques fragilités ;
- 15-20 : revoir les cartes prioritaires ;
- moins de 15 : reprendre le parcours réduit de 3 heures.

Concepts oraux a maitriser - ML, detection, causalite

Objectif du fichier : identifier les concepts a etudier pour etre capable de defendre le projet a l'oral.

Ce fichier n'est pas encore un cours complet. Il sert de carte de travail :

- quoi apprendre ;
- pourquoi le professeur peut le demander ;
- lien avec le projet DOTA / YOLO-OBB ;
- niveau de priorite ;
- statut de maitrise.

Derniere mise a jour : 2026-07-29

1. Diagnostic global

Le notebook avance correctement, mais la presentation du 2026-07-09 a revele un risque important : certaines questions conceptuelles simples peuvent bloquer si elles ne sont pas preparees.

Questions deja posees par le professeur :

- schema causal avec smoking, cancer, cancer gene ;
- explication de l'IoU dans le contexte de YOLO.

Conclusion :

- il ne suffit pas d'avoir du code ;
- il faut pouvoir expliquer les concepts sans support immediat ;
- les concepts ML et causalite doivent etre etudies en parallele du notebook.

2. Niveaux de priorite

Priorite 0 - A maitriser en premier

Concepts qui peuvent etre demandes directement et qui sont centraux.

Priorite 1 - A maitriser pour defendre le pipeline

Concepts importants pour expliquer les choix techniques du projet.

Priorite 2 - A maitriser pour la suite du rapport

Concepts qui deviendront centraux dans les parties causalite et interpretation.

3. Statuts possibles

- A faire : pas encore etudie serieusement.
- Fragile : deja vu, mais pas encore defendable oralement.
- Correct : explicable simplement, mais a renforcer.
- Solide : explicable avec exemple, limites et lien au projet.

4. Carte principale des concepts

Priorite	Bloc	Concept	Statut actuel	Pourquoi c'est important
0	Causalite	Causalite vs correlation	Fragile	Base de toutes les questions causales
0	Causalite	Traitement / outcome	Fragile	Necessaire pour formuler une question causale
0	Causalite	Confounder	Premier passage couvert	Question probable du professeur
0	Causalite	Mediator	Premier passage couvert	Piege classique dans les DAG
0	Causalite	Collider	Premier passage couvert	Piege classique : ne pas controler par erreur
0	Causalite	DAG	Premier passage couvert	Lire et expliquer un schema causal
0	Causalite	Backdoor path	Premier passage couvert	Comprendre l'ajustement causal
0	Detection	IoU	Fragile	Metrique de base en detection d'objets
0	Detection	Precision / recall	A faire	Base de l'evaluation du modele
0	Detection	mAP	A faire	Metrique principale pour detecteurs
0	YOLO	Prediction de classe et boite	Correct	Expliquer ce que le modele produit
0	YOLO	Confidence score	Fragile	Comprendre les detections retenues
0	YOLO	NMS	A faire	Comprendre le filtrage des detections
0	YOLO-OB	Boite orientee vs horizontale	Correct	Justifie le choix YOLO-OB
1	ML general	Train / validation / test	Correct	Eviter fuite et evaluation trompeuse
1	ML general	Overfitting / underfitting	Fragile	Expliquer generalisation
1	ML general	Fonction de perte	Fragile	Comprendre apprentissage modele
1	ML general	Descente de gradient	Correct	Relier au mini-exemple du notebook
1	Deep learning	Reseau de neurones	Fragile	Base de YOLO
1	Deep learning	CNN / convolution	A faire	Base de vision par ordinateur
1	YOLO	Backbone	Correct	Architecture YOLO
1	YOLO	Neck	Fragile	Detection multi-echelle
1	YOLO	Head	Fragile	Sorties du modele
1	Donnees	Desequilibre des classes	Correct	DOTA est desequilibre
1	Donnees	Objets difficiles	Correct	Analyse DOTA et erreurs futures
1	Donnees	Tuillage	Fragile	Necessaire pour grandes images
1	Methodologie	Data leakage	Correct	Risque majeur avec tuiles
2	Causalite appliquee	Question causale	A faire	Partie 4 du projet
2	Causalite appliquee	Variables d'ajustement	A faire	Partie 4/5 du projet
2	Causalite appliquee	Effet causal moyen	A faire	Estimation causale
2	Causalite appliquee	Effet heterogene	A faire	Lien avec arbres causaux
2	Causalite appliquee	Arbres causaux	A faire	Partie 5 du projet
2	Causalite appliquee	Forets causales	A faire	Partie 5 du projet

Priorite	Bloc	Concept	Statut actuel	Pourquoi c'est important
2	Analyse erreurs	Faux positif	A faire	Evaluer detections incorrectes
2	Analyse erreurs	Faux negatif	A faire	Evaluer objets manques
2	Analyse erreurs	Erreur de localisation	A faire	Lien direct avec IoU
2	Analyse erreurs	Erreur de classification	A faire	Classe predite incorrecte

5. Concepts deja presents dans le notebook, mais a rendre oraux

Ces concepts sont deja dans le notebook ou proches du notebook, mais il faut etre capable de les expliquer sans lire le code.

Concept	Section notebook	Risque oral
Format DOTA	Exploration	Expliquer les 8 coordonnees
Boites orientees	Exploration + YOLO-OBB	Justifier pourquoi OBB
Boites horizontales	Pretraitement	Expliquer perte d'information
Normalisation des coordonnees	Pretraitement	Expliquer pourquoi entre 0 et 1
Encodage des classes	Pretraitement	Expliquer pourquoi noms -> entiers
Objets difficiles	Exploration	Expliquer impact sur performance
Desequilibre de classes	Exploration	Expliquer pourquoi performance globale peut tromper
Tuillage	Mentionne, pas encore implemente	Expliquer risque de fuite
YOLO-OBB	Section modele	Expliquer architecture et sortie
Loss / gradient	Mini-exemple SGD	Relier a entraînement YOLO

6. Concepts absents ou trop peu vus

Ces concepts doivent etre ajoutes dans l'apprentissage oral avant d'aller trop loin.

Detection / evaluation

- IoU
- seuil IoU
- true positive
- false positive
- false negative
- precision
- recall
- courbe precision-recall
- AP
- mAP
- NMS
- confidence threshold

Causalite

- causalite vs association
- DAG
- traitement

- outcome
- confounder
- mediator
- collider
- backdoor path
- ajustement
- effet causal
- effet causal moyen
- effet heterogene
- variable observee vs non observee

Machine learning general

- apprentissage supervise
- features
- labels
- train / validation / test
- generalisation
- overfitting
- underfitting
- hyperparametres
- batch size
- epoch
- learning rate
- loss

Deep learning / vision

- reseau de neurones
- poids
- convolution
- feature map
- backbone
- neck
- head
- transfert learning
- fine-tuning
- GPU / CUDA

Methodologie projet

- data leakage
- split par image
- split par tuile
- stratification

- baseline
- comparaison de modeles
- reproductibilite
- limites experimentales

7. Ordre d'etude recommande

Phase A - Questions que le professeur vient deja de poser

1. IoU
2. Precision / recall
3. mAP
4. DAG simple
5. Confounder / mediator / collider
6. Exemple smoking, cancer, cancer gene

Objectif : ne plus etre surpris par une question courte.

Phase B - Defense du choix YOLO-OBB

1. Detection vs classification
2. YOLO en une passe
3. Backbone / neck / head
4. Confidence score
5. NMS
6. Boites orientees vs horizontales
7. Loss YOLO : classe + boite + confiance + orientation

Objectif : expliquer l'algorithme sans code.

Phase C - Methodologie d'entrainement

1. Train / validation / test
2. Overfitting / underfitting
3. Epoch / batch size / learning rate
4. GPU / CUDA
5. Tuilage
6. Data leakage
7. Baseline vs modele moderne

Objectif : defendre les choix experimentaux.

Phase D - Causalite appliquee au projet

1. Question causale dans DOTA
2. Traitement possible : petit objet, forte orientation, densite, classe rare
3. Outcome possible : erreur de detection, faux negatif, IoU faible
4. Variables d'ajustement
5. Arbres causaux
6. Forets causales

7. Interpretation : prediction vs causalite

Objectif : preparer les parties 4 et 5 du projet.

8. Questions orales probables

Detection / YOLO

- Qu'est-ce que l'IoU ?
- Pourquoi l'IoU ne suffit pas seule ?
- Quelle est la difference entre precision et recall ?
- C'est quoi la mAP ?
- Pourquoi YOLO plutot qu'un classifieur ?
- Pourquoi YOLO-OBb plutot que YOLO classique ?
- Que fait la NMS ?
- Que represente le confidence score ?
- Qu'est-ce que la loss du modele penalise ?
- Pourquoi les petits objets sont difficiles ?

Donnees / methodologie

- Pourquoi separer train et validation ?
- Qu'est-ce qu'une fuite de donnees ?
- Pourquoi le tuilage peut creer une fuite ?
- Pourquoi les classes desequilibrees posent probleme ?
- Pourquoi exclure les 171 annotations hors image ?
- Pourquoi normaliser les coordonnees ?
- Pourquoi garder les boites orientees ?

Causalite

- Difference entre correlation et causalite ?
- C'est quoi un confounder ?
- C'est quoi un mediator ?
- C'est quoi un collider ?
- Dans le schema smoking/cancer/gene, quel est le probleme causal ?
- Qu'est-ce qu'un traitement ?
- Qu'est-ce qu'un outcome ?
- Quelles variables faut-il ajuster ?
- Pourquoi prediction et causalite ne sont pas la meme chose ?

Projet DOTA

- Quelle est ta question causale future ?
- Quel serait ton traitement ?
- Quel serait ton outcome ?
- Quelles variables d'ajustement envisages-tu ?

- Comment relier les erreurs de YOLO a une analyse causale ?

9. Liens directs avec le projet DOTA

Concept	Lien avec le projet
IoU	Mesurer si une boîte prédite recouvre bien une boîte réelle
mAP	Evaluer globalement le détecteur
Faux négatif	Objet présent mais non détecté
Faux positif	Détection d'un objet qui n'existe pas
Orientation	DOTA contient des objets tournés
Petit objet	Véhicules et bateaux peuvent être difficiles
Classe rare	Certaines classes auront moins d'exemples
Tuilage	Nécessaire pour grandes images
Data leakage	Tuiles proches ne doivent pas être dans train et validation
Confounder	Variable qui influence à la fois le traitement et l'erreur
Traitement causal	Exemple : objet petit vs grand
Outcome causal	Exemple : erreur du détecteur
Arbres causaux	Trouver pour quels objets l'effet est plus fort

10. Definition du socle minimal a atteindre

Avant de reprendre un gros entraînement, l'objectif est d'atteindre ce niveau :

Pour chaque concept priorite 0

Je dois pouvoir dire :

1. définition simple ;
2. exemple hors projet ;
3. exemple dans DOTA ;
4. piège courant ;
5. pourquoi ça compte pour mon projet.

Exemple de niveau attendu

Pour IoU, je dois savoir :

- définir intersection et union ;
- expliquer pourquoi $\text{IoU} = 1$ est parfait ;
- expliquer pourquoi $\text{IoU} = 0$ est mauvais ;
- dire que des seuils IoU servent à décider si une détection est correcte ;
- relier ça aux boîtes YOLO-OB.

Pour confounder, je dois savoir :

- dire que c'est une variable qui influence le traitement et l'outcome ;
- donner l'exemple smoking / cancer / gene si pertinent ;
- expliquer pourquoi il faut ajuster ;
- expliquer qu'une mauvaise variable contrôlée peut biaiser l'analyse.

11. Plan d'action concret

Etape 1

Etudier et expliquer :

- IoU
- true positive / false positive / false negative
- precision / recall
- mAP

Etape 2

Etudier et expliquer :

- DAG
- traitement
- outcome
- confounder
- mediator
- collider

Etape 3

Etudier et expliquer :

- YOLO
- YOLO-OBB
- NMS
- confidence score
- loss

Etape 4

Etudier et expliquer :

- overfitting
- validation
- data leakage
- tuilage
- baseline

Etape 5

Formuler pour le projet :

- question causale provisoire ;
- traitement ;
- outcome ;
- variables d'ajustement ;
- variables a ne pas ajuster ;
- methode causale envisagee.

12. Règle de travail pour la suite

Pour chaque concept étudié, produire une mini-fiche :

```
[text]
Concept :
Definition simple :
Intuition :
Exemple général :
Lien avec DOTA :
Ou ça apparaît dans notre notebook/pipeline :
Piège fréquent :
Phrase orale :
Question probable :
Réponse courte :
```

Ces mini-fiches pourront ensuite être reprises dans :

- le notebook ;
- le rapport ;
- une future présentation ;
- une préparation orale rapide.

13. Suivi rapide

Objectif : garder une vision claire de l'avancement sans passer trop de temps sur la préparation orale.

Blocs à couvrir

Bloc	Concepts	Statut
Evaluation detection	IoU, TP/FP/FN, precision, recall, mAP	Couvert, à pratiquer
YOLO pratique	confidence, NMS, loss, OBB	Premier passage couvert
Causalité de base	DAG, traitement, outcome, confounder, mediator, collider	Premier passage couvert
Methodologie ML	overfitting, validation, leakage, baseline	A faire
Causalité appliquée DOTA	traitement, outcome, ajustements, erreurs du détecteur	A faire

Règle : couvrir 2 ou 3 cartes, puis revenir au projet si le bloc est suffisamment clair.

14. Cartes orales - Evaluation en detection

Carte 1 - IoU

Question probable du prof :

- Comment sais-tu si une boîte prédite par YOLO est correcte ?

Réponse en 20 secondes :

- On utilise l'IoU, pour Intersection over Union. Ça mesure le chevauchement entre la boîte prédite et la boîte réelle. Si les deux boîtes se superposent parfaitement, l'IoU vaut 1. Si elles ne se touchent pas, l'IoU vaut 0. En détection, on utilise souvent un seuil d'IoU pour décider si une prédiction compte comme correcte.

Intuition :

- Intersection = partie commune entre les deux boîtes.
- Union = surface totale couverte par les deux boîtes.
- IoU = intersection / union.

Mini-exemple :

- Boîte prédite presque au bon endroit : IoU élevée.

- Bonne classe mais boîte loin de l'objet : IoU faible.

Lien avec DOTA :

- Dans DOTA, on veut savoir si YOLO-OBb localise bien les avions, bateaux, véhicules, etc.
- Comme les objets peuvent être tournés, l'IoU doit idéalement comparer des boîtes orientées.

Où ça apparaît dans notre notebook/pipeline :

- On n'a pas encore calculé l'IoU dans le notebook, parce qu'il faut d'abord entraîner un modèle et obtenir des prédictions.
- Les labels YOLO-OBb exportés serviront de boîtes réelles.
- Les futures prédictions YOLO-OBb seront comparées à ces boîtes réelles avec une métrique de type IoU.

Piège :

- Prédire la bonne classe ne suffit pas. Si la boîte est mauvaise, la détection est mauvaise.

Phrase orale utile :

- "L'IoU me permet de mesurer la qualité géométrique de la détection, pas seulement la classe prédite."

Statut : Correct, à pratiquer oralement.

Carte 2 - True positive, false positive, false negative

Question probable du prof :

- Quand est-ce qu'une détection est considérée bonne ou mauvaise ?

Réponse en 20 secondes :

- Une détection est un true positive si le modèle prédit la bonne classe et que la boîte recouvre assez bien un objet réel, selon un seuil d'IoU. Une false positive est une détection annoncée par le modèle mais qui ne correspond pas à un vrai objet. Une false negative est un objet réel que le modèle n'a pas détecté.

Intuition :

- True positive = objet trouvé correctement.
- False positive = fausse alerte.
- False negative = objet manqué.

Mini-exemple :

- YOLO détecte un avion au bon endroit : true positive.
- YOLO détecte un avion dans une zone vide : false positive.
- Un avion existe dans l'image mais YOLO ne le détecte pas : false negative.

Lien avec DOTA :

- Les petits objets peuvent augmenter les false negatives.
- Les zones denses peuvent augmenter les false positives.
- Les objets orientés peuvent causer des erreurs de localisation.

Où ça apparaît dans notre notebook/pipeline :

- L'exploration a montré des objets petits, des classes déséquilibrées et des boîtes orientées.
- Après entraînement, on pourra transformer les prédictions en catégories d'erreurs : objet trouvé, objet manqué, fausse détection, mauvaise localisation.
- Ces erreurs seront aussi utiles plus tard pour la partie causale du projet.

Piège :

- Une prédiction peut être mauvaise même si elle "semble proche" : il faut une règle, souvent basée sur l'IoU.

Phrase orale utile :

- "Les erreurs du détecteur ne sont pas toutes du même type : il peut inventer un objet, manquer un objet, ou mal localiser un objet."

Statut : A renforcer.

Carte 3 - Precision et recall

Question probable du prof :

- Quelle est la différence entre precision et recall ?

Reponse en 20 secondes :

- La precision repond a la question : parmi les detections du modele, combien sont correctes ? Le recall repond a la question : parmi les vrais objets presents, combien le modele a-t-il retrouves ? Donc la precision mesure les fausses alertes, tandis que le recall mesure les objets manques.

Intuition :

- Precision elevee = peu de fausses detections.
- Recall eleve = peu d'objets oublies.

Mini-exemple :

- Modele tres prudent : peu de detections, precision haute, recall bas.
- Modele trop agressif : beaucoup de detections, recall haut, precision basse.

Lien avec DOTA :

- Si on veut detecter tous les petits vehicules, il faut un bon recall.
- Si on veut eviter de fausses detections dans des zones complexes, il faut une bonne precision.

Ou ca apparait dans notre notebook/pipeline :

- Le notebook a deja montre que certaines classes sont beaucoup plus frequentes que d'autres.
- Une precision globale peut cacher de mauvaises performances sur des classes rares.
- Quand on evaluera YOLO-OB, il faudra regarder precision et recall, idealement par classe.

Piege :

- Precision et recall sont souvent en tension. Ameliorer l'un peut degrader l'autre.

Phrase orale utile :

- "La precision me dit si les detections sont fiables; le recall me dit si le modele oublie beaucoup d'objets."

Statut : A renforcer.

Carte 4 - mAP

Question probable du prof :

- C'est quoi la mAP et pourquoi on l'utilise en detection ?

Reponse en 20 secondes :

- La mAP veut dire mean Average Precision. Elle resume la performance d'un detecteur en combinant precision et recall, puis en moyennant le resultat sur les classes. C'est utile parce qu'un detecteur ne produit pas seulement une classe : il produit plusieurs boites avec des scores de confiance.

Intuition :

- Pour une classe, on regarde comment la precision et le recall changent quand on varie le seuil de confiance.

- Cette relation donne une courbe precision-recall.
- L'AP resume cette courbe pour une classe.
- La mAP moyenne les AP sur plusieurs classes.

Mini-exemple :

- Si le modele detecte tres bien les p lane, AP plane sera elevee.
- S'il detecte mal les bridge, AP bridge sera faible.
- La mAP resume les performances sur toutes les classes.

Lien avec DOTA :

- DOTA contient 15 classes.
- Certaines classes sont tres frequentes, comme ship ou small-vehicle.
- D'autres sont plus rares.
- La mAP aide a evaluer le detecteur sans regarder seulement une classe dominante.

Ou ca apparait dans notre notebook/pipeline :

- Le notebook a deja une section Evaluation prevue du detecteur qui introduit la mAP.
- La vraie mAP sera calculee apres l'entrainement YOLO-OBB, quand on aura des predictions sur la validation.
- Il faudra idealement regarder la mAP globale et les resultats par classe.

Piege :

- Une bonne mAP globale peut cacher une mauvaise performance sur une classe rare ou difficile.
- Il ne faut pas conclure que le modele est bon partout seulement avec une moyenne.

Phrase orale utile :

- "La mAP donne une evaluation globale du detecteur, mais dans DOTA je devrai aussi regarder les performances par classe, taille et orientation."

Statut : A renforcer.

Carte 5 - Confidence score

Question probable du prof :

- Que represente le score de confiance dans YOLO ?

Reponse en 20 secondes :

- Le score de confiance indique a quel point le modele est confiant dans une detection. Il sert a classer et filtrer les predictions. Une detection avec une confiance tres faible peut etre ignoree, tandis qu'une detection tres confiante a plus de chances d'etre garde.

Intuition :

- Le modele ne dit pas seulement "il y a un avion".
- Il dit plutot "je pense qu'il y a un avion ici, avec une certaine confiance".

Mini-exemple :

- Detection p lane avec confiance 0.92 : prediction assez forte.
- Detection p lane avec confiance 0.18 : prediction faible, probablement filter.

Lien avec DOTA :

- Les images aeriennes peuvent contenir des zones complexes : batiments, routes, ports, petits objets.
- Le modele peut produire des detections incertaines dans ces zones.

- Le score de confiance aide à décider quelles détections garder.

Où ça apparaît dans notre notebook/pipeline :

- Le notebook n'a pas encore de prédictions YOLO, donc pas encore de scores de confiance réels.
- Après entraînement, chaque prédiction YOLO-OBDD aura un score.
- Ces scores serviront à calculer précision, rappel et mAP.

Piège :

- Une confiance élevée ne garantit pas que la boîte est bien placée.
- Il faut combiner confiance, classe prédite et IoU.

Phrase orale utile :

- "Le score de confiance sert à filtrer les détections, mais il ne remplace pas l'évaluation géométrique avec l'IoU."

Statut : À faire pratiquer.

Carte 6 - NMS

Question probable du prof :

- Pourquoi YOLO a besoin de NMS ?

Réponse en 20 secondes :

- YOLO peut prédire plusieurs boîtes pour le même objet. La NMS, Non-Maximum Suppression, garde la détection la plus confiante et supprime les détections trop proches qui représentent probablement le même objet.

Intuition :

- Un seul avion peut générer plusieurs détections proches.
- Sans filtrage, on compterait plusieurs fois le même objet.
- La NMS nettoie les prédictions.

Mini-exemple :

- Trois boîtes détectent le même avion.
- Elles ont des confiances 0.91, 0.84 et 0.70.
- La NMS garde souvent celle à 0.91 et supprime les autres si elles se chevauchent trop.

Lien avec DOTA :

- DOTA peut contenir des zones denses avec beaucoup de véhicules ou bateaux proches.
- La NMS est utile, mais elle doit être réglée prudemment.
- Si elle est trop agressive, elle peut supprimer des objets réels proches les uns des autres.

Où ça apparaît dans notre notebook/pipeline :

- La NMS n'apparaîtra vraiment qu'après les prédictions YOLO-OBDD.
- Elle fait partie du post-traitement du modèle.
- Elle influencera les faux positifs, faux négatifs, précision et rappel.

Piège :

- NMS n'est pas l'entraînement du modèle; c'est une étape après prédiction.
- Elle ne corrige pas un modèle mauvais, elle filtre seulement les détections candidates.

Phrase orale utile :

- "La NMS évite de compter plusieurs fois le même objet, mais dans les zones denses elle peut aussi supprimer des objets proches si elle est trop stricte."

Statut : A faire pratiquer.

Carte 7 - Loss YOLO

Question probable du prof :

- Qu'est-ce que YOLO apprend pendant l'entraînement ?

Reponse en 20 secondes :

- YOLO apprend en minimisant une loss, c'est-à-dire une mesure d'erreur entre ses prédictions et les annotations. Cette erreur pénalise surtout trois choses : une mauvaise localisation de la boîte, une mauvaise classe et une mauvaise confiance. En YOLO-OB, la localisation doit aussi respecter l'orientation de l'objet.

Intuition :

- La loss est le signal qui dit au modèle dans quelle direction corriger ses poids.
- Plus la prédiction est loin de l'annotation, plus la pénalité est forte.
- Pendant l'entraînement, le modèle fait beaucoup de petites corrections.

Mini-exemple :

- Si un avion est annoté à gauche de l'image mais que YOLO le prédit trop à droite, la partie localisation de la loss augmente.
- Si la boîte est bonne mais la classe prédite est `ship` au lieu de `plane`, la partie classification augmente.
- Si le modèle est très confiant dans une mauvaise détection, l'erreur est plus grave.

Lien avec DOTA :

- Dans DOTA, les objets sont souvent petits, denses et orientés.
- La loss doit donc aider le modèle à apprendre des boîtes précises, pas seulement des classes.
- Pour YOLO-OB, une boîte mal orientée peut être pénalisée même si le centre est proche de l'objet.

Où ça apparaît dans notre notebook/pipeline :

- Le notebook prépare les labels YOLO-OB qui serviront de vérité terrain pendant l'entraînement.
- La cellule d'entraînement est préparée mais désactivée par défaut avec `RUN_YOLO_OB_TRAINING = False`.
- Quand l'entraînement sera lancé, Ultralytics affichera des pertes comme la loss de boîte et la loss de classe.

Piège :

- La loss n'est pas la même chose que la mAP.
- La loss sert à entraîner le modèle; la mAP sert à évaluer sa qualité sur validation.
- Une loss qui baisse est bon signe, mais il faut vérifier les métriques de validation.

Phrase orale utile :

- "La loss est le signal d'apprentissage : elle pénalise les erreurs de boîte, de classe et de confiance, puis le modèle ajuste ses poids pour réduire cette erreur."

Statut : A renforcer.

Carte 8 - YOLO classique vs YOLO-OB

Question probable du prof :

- Pourquoi utiliser YOLO-OB au lieu d'un YOLO classique ?

Reponse en 20 secondes :

- Un YOLO classique prédit des boîtes horizontales, alignées avec les axes de l'image. YOLO-OB prédit des boîtes orientées, donc des boîtes qui peuvent tourner avec l'objet. Dans DOTA, c'est important parce que les avions, bateaux,

ponts et vehicules peuvent etre dans n'importe quelle orientation.

Intuition :

- Boite horizontale = rectangle droit, meme si l'objet est diagonal.
- Boite orientee = rectangle qui suit mieux la direction de l'objet.
- Moins de fond inutile dans la boite signifie une localisation plus precise.

Mini-exemple :

- Un avion diagonal dans une image satellite.
- Avec une boite horizontale, la boite englobe l'avion plus beaucoup de fond.
- Avec une boite orientee, la boite suit l'avion et represente mieux sa vraie forme.

Lien avec DOTA :

- DOTA fournit directement des annotations avec 4 coins, donc le dataset est naturellement compatible avec les boites orientees.
- Notre exploration a montre que l'orientation mediane est loin de 0 degre.
- Cela justifie de garder les OBB comme representation principale.

Ou ca apparait dans notre notebook/pipeline :

- Le notebook exporte les labels YOLO-OBB au format `class_index x1 y1 x2 y2 x3 y3 x4 y4`.
- On garde aussi des boites horizontales derivees pour une baseline simple ou pour analyser certaines erreurs.
- La section YOLO explique deja pourquoi YOLO-OBB est plus coherent avec DOTA.

Piege :

- YOLO-OBB n'est pas automatiquement meilleur dans tous les cas.
- Il est plus adapte a DOTA, mais il demande des annotations correctes, un format exact et une evaluation compatible avec les boites orientees.

Phrase orale utile :

- "YOLO classique localise avec des rectangles horizontaux; YOLO-OBB localise avec des rectangles orientes, ce qui correspond beaucoup mieux aux objets de DOTA."

Statut : A renforcer.

15. Cartes orales - Causalite de base et application DOTA

Carte 9 - DAG

Question probable du prof :

- A quoi sert un DAG en causalite ?

Reponse en 20 secondes :

- Un DAG est un graphe oriente sans cycle qui represente mes hypotheses sur les relations causales. Les fleches indiquent la direction supposee des causes. Il m'aide a identifier les chemins de confusion, choisir les variables d'ajustement et eviter de controler sur un mediator ou un collider.

Mini-exemple :

- classe -> tres petit
- classe -> detection
- tres petit -> detection

Lien DOTA :

- La classe peut influencer la taille typique et la facilité de détection. Le DAG montre pourquoi la classe doit être considérée avant d'interpréter la différence petits/grands.

Piège :

- Un DAG n'est pas appris automatiquement par les corrélations. Il formalise des hypothèses qui doivent être défendues.

Phrase orale utile :

- "Le DAG rend mes hypothèses visibles et me dit quels chemins non causaux je dois bloquer."

Statut : Premier passage couvert, à redessiner sans support.

Carte 10 - Traitement, outcome et estimand

Question probable du prof :

- Quelle est exactement ta question causale ?

Réponse en 20 secondes :

- Mon traitement vaut 1 si l'objet appartient au premier quartile de taille relative calculé sur train. Mon outcome vaut 1 si le modèle produit une détection de même classe, de confiance au moins 0.25 et d'IoU orientée au moins 0.50. J'estime l'effet moyen sur les objets uniques de validation.

Lien DOTA :

- Le seuil est défini avec train pour ne pas le choisir après avoir vu les outcomes validation.
- Une seule instance est gardée par objet original pour éviter de surpondérer les objets dupliqués par la grille.

Piège :

- "Petit" est une condition observationnelle. Plusieurs interventions différentes pourraient rendre un objet petit.

Phrase orale utile :

- "Je définis D, Y et la population avant l'estimation, sinon le mot effet reste ambigu."

Statut : Premier passage couvert.

Carte 11 - Confounder

Question probable du prof :

- Qu'est-ce qu'un confounder et quel est ton exemple dans DOTA ?

Réponse en 20 secondes :

- Un confounder est une cause commune du traitement et de l'outcome. Dans DOTA, la classe est un exemple : certaines classes sont typiquement plus petites et la classe influence aussi la facilité de détection. Sans ajuster sur elle, la comparaison petits/grands mélange taille et composition des classes.

Schema :

- `tres petit <- classe -> detection correcte`

Piège :

- Une variable associée aux deux n'est pas automatiquement un confounder. Elle doit précéder causalement les deux dans le DAG.

Phrase orale utile :

- "J'ajuste sur la classe pour bloquer un chemin arrière, pas parce qu'elle est seulement corrélée."

Statut : Premier passage couvert.

Carte 12 - Mediator

Question probable du prof :

- Pourquoi ne faut-il pas toujours ajuster sur toutes les variables disponibles ?

Reponse en 20 secondes :

- Un mediator est cause par le traitement et transmet une partie de son effet vers l'outcome. Si je veux l'effet total, l'ajuster bloquerait precisement une partie de l'effet recherche. Par exemple, la petite taille peut reduire la qualite des features, qui reduit ensuite la detection.

Schema :

- tres petit -> qualite des features -> detection

Lien DOTA :

- Le score de confiance et les features internes sont produits apres le traitement, donc ne sont pas des ajustements principaux.

Piege :

- Ajuster sur un mediator n'est pas toujours faux, mais cela change la question vers un effet direct.

Phrase orale utile :

- "Plus de variables n'est pas toujours mieux : une variable post-traitement peut retirer l'effet que je cherche."

Statut : Premier passage couvert.

Carte 13 - Collider

Question probable du prof :

- Qu'est-ce qu'un collider et pourquoi est-ce un piege ?

Reponse en 20 secondes :

- Un collider est une consequence commune de deux variables. Sans conditionnement, le chemin est ferme. Si je conditionne sur le collider, je peux creer une association artificielle entre ses causes. Par exemple, petite taille et scene complexe peuvent toutes deux influencer le fait qu'une tuile soit retenue.

Schema :

- tres petit -> tuile selectionnee <- scene complexe

Lien DOTA :

- Le rejet des fragments ambigus peut selectionner certaines positions ou tailles. Cette limite doit etre declaree.

Piege :

- Un collider est l'inverse logique d'un confounder pour l'ajustement : le controler peut ouvrir un biais.

Phrase orale utile :

- "Je ne controle pas une variable seulement parce qu'elle est disponible ; je regarde sa place dans le DAG."

Statut : Premier passage couvert.

Carte 14 - Backdoor path et ajustement

Question probable du prof :

- Comment choisis-tu les variables d'ajustement ?

Reponse en 20 secondes :

- Je cherche les chemins entre traitement et outcome qui commencent par une fleche entrant dans le traitement. Je choisis un ensemble de variables pre-traitement qui bloque ces backdoors, sans bloquer les mediateurs ni ouvrir les colliders.

Ensemble principal DOTA :

- classe ;
- orientation ;
- ratio de forme ;
- densité ;
- source et GSD ;
- position du centre dans la tuile.

Variables évitées :

- aire exacte, car elle définit D ;
- fraction conservée, car elle relève de la sélection par tuilage et peut être

une variable post-traitement ;

- confiance et IoU, car elles sont post-traitement ou outcome.

Phrase orale utile :

- "Mon ensemble d'ajustement vient du DAG et de la chronologie causale, pas d'une sélection automatique de toutes les colonnes."

Statut : Premier passage couvert.

Carte 15 - AIPW et cross-fitting

Question probable du prof :

- Pourquoi utiliser AIPW plutôt qu'une simple différence de moyennes ?

Réponse en 20 secondes :

- La différence brute peut être confondue. AIPW combine un modèle de l'outcome et un score de propension, puis corrige les prédictions avec des résidus pondérés. Le cross-fitting produit ces prédictions sur des folds non utilisés pour entraîner les modèles nuisances, groupes par image source.

Intuition :

- g-computation prédit les deux mondes ;
- propension mesure le mécanisme de traitement observé ;
- la correction résiduelle rapproche l'estimation des outcomes observés.

Piège :

- Doublement robuste ne signifie pas robuste aux confounders non observés, à la mauvaise positivité ou à un traitement mal défini.

Phrase orale utile :

- "AIPW combine deux modèles et une correction hors fold, mais mes hypothèses causales restent indispensables."

Statut : Premier passage couvert, formule à revoir.

Carte 16 - Arbre causal et effet hétérogène

Question probable du prof :

- Pourquoi un arbre causal si tu as déjà un effet moyen ?

Réponse en 20 secondes :

- L'effet moyen peut cacher des sous-groupes. Un arbre causal cherche des divisions où l'effet estimé diffère, par exemple selon la classe, l'orientation ou la densité. Dans mon pipeline, une moitié des images choisit les divisions et l'autre estime

les effets des feuilles pour limiter le biais.

Lien DOTA :

- Une pénalité de petite taille peut être plus forte dans une scène dense ou pour certaines classes.

Piège :

- Une feuille extrême avec peu d'images peut être du bruit. L'arbre est exploratoire et demande des intervalles et une validation externe.

Phrase orale utile :

- "L'arbre ne remplace pas l'ATE ; il explore ou l'effet peut être différent et avec quelle incertitude."

Statut : Premier passage couvert.