

Détection d'objets dans des images satellites et aériennes

DOTA-v1.0 - YOLO HBB, YOLO-ORB et inférence causale sur les erreurs de détection

Projet	Projet individuel 11
Dataset	DOTA-v1.0
Environnement	Python 3.14, PyTorch CUDA 13.0, RTX 4060
Protocole	180 images train, 60 images validation, tuiles 1024
Date	29 juillet 2026

Ce rapport sépare explicitement la performance prédictive du détecteur et l'estimation causale d'un effet sur ses erreurs.

Table des matières

1. Résumé exécutif
2. 1. Exploration du jeu de données et choix des algorithmes
3. 2. Prétraitement, tuilage et variables dérivées
4. 3. Modèles prédictifs et apprentissage profond
5. 4. Formulation de la question causale
6. 5. Estimation causale et effets hétérogènes
7. 6. Interprétation, limites et conclusion
8. Reproductibilité et références

Résumé exécutif

Ce projet étudie la détection de 15 catégories d'objets dans des images aériennes DOTA-v1.0. Les images sources sont séparées avant le tuilage afin d'éviter toute fuite. Un sous-ensemble stratifié de 180 images d'entraînement et 60 images de validation est converti simultanément en boîtes horizontales et orientées.

Trois configurations comparables sont évaluées. Le meilleur score mAP50-95 est obtenu par YOLO26n-OBB-1024 (0.186), avec une mAP50 de 0.274. Les résultats modestes sont cohérents avec la brièveté de l'entraînement, la petite taille du sous-ensemble et la difficulté des objets minuscules.

L'analyse causale définit le traitement comme l'appartenance au premier quartile de taille calculé sur train, et l'outcome comme une détection de même classe, confiance au moins 0,25 et IoU orientée au moins 0,50. L'effet AIPW vaut -0.368, IC bootstrap groupe 95 % [-0.530, -0.166]. Cette valeur est interprétée comme une différence absolue de probabilité sous des hypothèses d'identification explicites, et non comme le résultat d'une expérience randomisée.




Figure 1 - Comparaison globale des détecteurs sur la validation.

1. Exploration du jeu de données et choix des algorithmes

1.1 Données et difficultés

DOTA-v1.0 contient de grandes images satellites et aériennes. Chaque objet est décrit par quatre coins, une classe et un indicateur de difficulté.

L'exploration complète du notebook recense 98 990 objets train et 28 853 objets validation. Les orientations médianes proches de 47° en train et 52° en validation justifient une représentation orientée.

Les objets varient fortement en aire et les classes sont déséquilibrées. Les petits véhicules sont nombreux, tandis que les hélicoptères et certaines infrastructures sont rares.

1.2 Algorithmes considérés

Algorithme	Pertinence	Décision
YOLO-OBB	Détection rapide avec boîtes orientées	Modèle principal
YOLO HBB	Détecteur simple sur boîtes converties	Baseline
Faster R-CNN / RetinaNet	Alternatives HBB plus lourdes	Non retenues pour ce protocole
DETR	Approche moderne mais coûteuse en données/calcul	Piste future
Classifieur global	Ignore localisation et multiplicité	Inadapté à l'état brut

Les risques identifiés avant l'entraînement sont la fuite entre tuiles d'une même source, la perte géométrique des HBB, le déséquilibre des classes et la confusion entre précision prédictive et causalité.

2. Prétraitement, tuilage et variables dérivées

2.1 Sélection stratifiée

Les images sont sélectionnées avant le tuilage. La stratégie garantit plusieurs images par classe quand les données le permettent, puis équilibre des strates combinant classe dominante et densité d'objets. Elle améliore la couverture sans prétendre supprimer le déséquilibre naturel.

Tâche	Split	Tuiles	Négatives	Objets	Classes
HBB	train	912	111	6515	15
HBB	val	245	33	1972	15
OBB	train	912	111	6515	15
OBB	val	245	33	1972	15

Contrôle critique : 0 image source partagée entre train et validation.

2.2 Tuilage et fragments

Les tuiles mesurent 1024 x 1024 pixels. Le stride train de 824 crée un chevauchement de 200 pixels pour mieux conserver les objets proches des bords. Le stride validation de 1024 limite la redondance.

Un objet est gardé si au moins 70 % de sa surface reste dans la tuile. Une tuile contenant un fragment entre 20 % et 70 % est rejetée comme ambiguë. Les fragments inférieurs à 20 % sont ignorés.

Un échantillon de tuiles négatives est conservé pour apprendre le fond. Les HBB et OBB partagent exactement les mêmes fichiers image.

2.3 Variables

Niveau	Variables principales
Image	source, GSD, largeur, hauteur, classe dominante, densité
Objet	classe, difficulté, aire, orientation, ratio de forme
Tuile	position x/y, taille, nombre d'objets, tuile négative
Fragment	fraction conservée, aire clippée, marge au bord
Prédiction	classe, confiance, IoU associée, détection correcte

3. Modèles prédictifs et apprentissage profond

3.1 Protocole d'entraînement

Les modèles utilisent YOLO26n, un backbone initialisé par transfert depuis COCO, 20 epochs, la graine 42, l'AMP et l'early stopping. Les workers sont fixés à zéro pour éviter les blocages observés sous Windows.

La baseline HBB et le modèle OBB à 640 utilisent les mêmes tuiles, la même graine et le même point de départ général. Une variante OBB à 1024 teste l'hypothèse qu'une résolution d'entrée plus élevée aide les petits objets.

Les poids best.pt sont sélectionnés selon la validation plutôt que de supposer que la dernière époque est la meilleure.

Modèle	Tâche	imgsz	Précision	Recall	F1	mAP50	mAP50-95
YOLO26n-HBB-640	HBB	640	0.451	0.283	0.347	0.257	0.145
YOLO26n-OBB-1024	OBB	1024	0.574	0.290	0.385	0.274	0.186
YOLO26n-OBB-640	OBB	640	0.256	0.299	0.276	0.239	0.146

Le modèle retenu pour construire l'outcome causal est YOLO26n-OBB-1024 : précision 0.574, recall 0.290, F1 0.385, mAP50 0.274 et mAP50-95 0.186.




Figure 2 - AP50-95 par classe et par modèle.

3.2 Résultats par classe

Groupe	Classe	AP50-95
Meilleure	tennis-court	0.544
Meilleure	plane	0.384
Meilleure	ship	0.325
Meilleure	large-vehicle	0.249
Meilleure	roundabout	0.232
Faible	helicopter	0.000
Faible	basketball-court	0.032
Faible	soccer-ball-field	0.082
Faible	harbor	0.095
Faible	storage-tank	0.130

Ces AP doivent être lues avec les effectifs : une classe rare peut avoir une estimation très variable. Inversement, une classe fréquente peut rester difficile si ses objets sont minuscules ou très denses.




Figure 3 - Exemples de prédictions de YOLO26n-OBb-1024 sur validation.




Figure 4 - Taux de détection correcte selon taille et orientation.

L'analyse d'erreurs confirme que les scores globaux cachent des écarts de taille, orientation et classe. Quelques pixels de décalage réduisent beaucoup plus l'IoU d'un petit objet que celle d'un grand objet.

4. Formulation de la question causale

4.1 Traitement, outcome et estimand

Élément	Définition
Traitement D	1 si aire relative de tuile $\leq$ premier quartile train, 0 sinon
Outcome Y	1 si même classe, confiance $\geq 0,25$ et IoU OBB $\geq 0,50$
Population	1646 objets uniques de 53 images validation
Estimand	ATE sur la probabilité de détection correcte

Quel est l'effet d'être un objet très petit sur la probabilité d'une détection correcte (IoU ≥ 0.50), après ajustement sur la classe, l'orientation, la densité, la source, le GSD, le ratio de forme et la position du centre dans la tuile ?




Figure 5 - DAG simplifié guidant l'ajustement.

4.2 Ajustement et hypothèses

L'ajustement inclut classe, orientation, log du ratio de forme, densité de tuile, source, GSD et position du centre dans la tuile. L'aire exacte est exclue parce qu'elle définit le traitement. La fraction conservée, la confiance et l'IoU sont exclues car elles relèvent de la sélection, du post-traitement ou de l'outcome.

L'échangeabilité conditionnelle suppose l'absence de confondeurs non observés après ajustement. Cette hypothèse est menacée par le flou, le contraste, l'occultation et la qualité d'annotation.

La positivité exige des petits et non petits comparables dans les profils analysés. Les classes rares et typiquement minuscules peuvent avoir un support limité.

La cohérence est fragile parce que plusieurs interventions pourraient rendre un objet petit. L'absence d'interférence est aussi imparfaite dans les scènes denses à cause de la NMS et de max_det.

5. Estimation causale et effets hétérogènes

5.1 Méthodes comparées

Méthode	Effet	IC bas	IC haut
Difference brute	-0.207	-0.520	0.052
G-computation	-0.170	-0.260	-0.096
IPW	-0.620	-0.860	-0.352
AIPW doublement robuste	-0.368	-0.530	-0.166

La différence brute compare les taux sans ajustement. La g-computation prédit les deux outcomes. L'IPW pondère par la probabilité du traitement observé. L'AIPW combine les deux modèles et corrige avec les résidus.

Les modèles nuisances sont prédits hors fold avec GroupKFold par image. Les intervalles bootstrap rééchantillonnent les images entières afin de respecter la dépendance entre objets d'une même scène.




Figure 6 - Effets moyens et intervalles bootstrap groupe.

Résultat principal : AIPW = -0.368, IC 95 % [-0.530, -0.166]. Le taux observé est 30.7 % chez les traités et 51.3 % chez les contrôles.




Figure 7 - Recouvrement des scores de propension.

La fraction des objets dont le score est entre 0,1 et 0,9 vaut 76.5 %. Un bon recouvrement réduit l'extrapolation, sans démontrer l'absence de confondeurs non observés.

5.2 Sensibilité

Spécification	Effet	IC bas	IC haut
IoU ≥ 0.40	-0.374	-0.518	-0.190
IoU ≥ 0.50	-0.368	-0.519	-0.183
IoU ≥ 0.60	-0.332	-0.480	-0.141
Propension clip 0.02	-0.274	-0.507	0.085
Propension clip 0.10	-0.388	-0.504	-0.246
Graine nuisances 7	-0.370	-0.535	-0.155
Graine nuisances 99	-0.366	-0.522	-0.177

La variation des seuils IoU et du clipping montre quelles parties de la conclusion sont stables et lesquelles dépendent du choix de spécification. Elle ne remplace pas une analyse de confondeur non observé.

5.3 Hétérogénéité

Arbre causal honnête conservateur sur pseudo-outcomes AIPW




Figure 8 - Arbre causal honnête sur pseudo-outcomes AIPW.

Feuille	Objets	Images	Effet	IC 95 %	Classe dominante
2	795	12	-0.457	[-0.646; -0.221]	ship
1	296	20	-0.131	[-0.640; 0.474]	plane




Figure 9 - Distribution des effets conditionnels estimés par forêt sur pseudo-outcomes.

La structure de l'arbre est choisie sur une moitié des images et les effets des feuilles sur l'autre. La forêt utilise des prédictions croisées par image. L'arbre est volontairement limité à une division et à de grandes feuilles pour réduire les sous-groupes artificiels. Ces résultats sont exploratoires : la méthode est une approximation pédagogique d'une forêt causale spécialisée.

6. Interprétation, limites et conclusion

6.1 Interprétation prédictive

Le meilleur modèle du protocole est YOLO26n-OBB-1024 avec mAP50-95 0.186. Ce résultat décrit la capacité de localisation et classification sur les images validation sélectionnées. Il ne doit pas être transformé en affirmation causale sur la taille ou la résolution.

6.2 Interprétation causale

Sous les hypothèses d'identification, l'effet AIPW de la condition très petite est estimé à -0.368 point de probabilité, avec IC 95 % [-0.530, -0.166]. Il s'agit d'une différence absolue moyenne dans la population analysée, pas d'une baisse relative universelle.

6.3 Limites

- Sous-ensemble stratifié plutôt que DOTA complet.
- Vingt epochs et une petite famille de modèles.
- Classes rares et positivité locale limitée.
- Traitement non randomisé et intervention de taille ambiguë.
- Flou, contraste, occultation et qualité d'annotation non observés.
- Sélection induite par le tuilage et le rejet des fragments ambigus.
- Interférence possible entre objets via NMS, densité et max_det.
- Outcome dépendant d'un détecteur et de seuils choisis.
- Forêt sur pseudo-outcomes, non implémentation complète d'une GRF.
- Arbre honnête volontairement peu profond pour limiter les sous-groupes instables.
- Bootstrap groupe sans réajustement complet des modèles nuisances.

6.4 Conclusion

Le projet fournit une chaîne complète et reproductible allant des annotations DOTA aux tuiles, aux modèles HBB/OBB, à l'évaluation par classe et à une table causale par objet. Le résultat prédictif mesure ce que le détecteur accomplit. L'analyse causale estime ensuite un contraste sur ses erreurs, avec des hypothèses, des intervalles et une sensibilité explicites. Cette séparation est la conclusion méthodologique centrale.

Reproductibilité et références

Élément	Valeur
Graine	42
Images source	180 train / 60 validation
Tuiles	1024 pixels
Stride	824 train / 1024 validation
Chevauchement source	0 image
Architecture	YOLO26n HBB et OBB
Environnement	Python 3.14.3, torch 2.11.0+cu130
GPU	NVIDIA GeForce RTX 4060
Artefacts	CSV, JSON, figures, poids best/last et notebook exécuté

- DOTA-v1.0 : <https://captain-whu.github.io/DOTA/>
- Ultralytics YOLO OBB : <https://docs.ultralytics.com/tasks/obb/>
- Sujet officiel du projet, fichier Subject.pdf fourni.
- Code, notebook et sorties : dépôt dota-minimap-object-detection.